5. Divide and Conquer

Divide-and-Conquer: Allgemeines Prinzip für effiziente Problemlösungsstrategien.

Vorgehensweise:

- Teile: Zerlege das Problem in mehrere, meist zwei, kleinere Teilprobleme.
- Herrsche (Conquer): Löse jeden der Teilprobleme rekursiv.
- Zusammenführen (Combine): Fasse die Lösungen der Teilprobleme zu einer Gesamtlösung zusammen.

Zitat:

Divide et impera. Veni, vidi, vici.

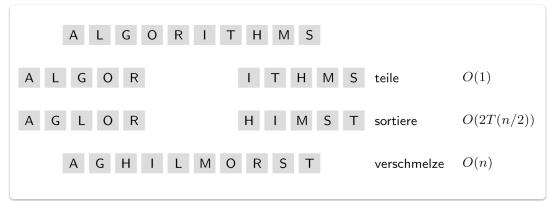
Julius Caesar

Sortieren: Wiederholung

- Primitive Sortierverfahren:
 - Bubblesort
 - Insertionsort
 - Selectionsort
- Laufzeit: Die Laufzeit dieser Verfahren liegt im Worst- und Average-Case immer in $\Theta(n^2)$.
- Frage: Kann man im Worst- und Average-Case schneller sortieren?
- Antwort: Ja. Mergesort ist ein Beispiel dafür.

Mergesort (Sortieren durch Mischen)

- Mergesort:
 - Teile Array in zwei Hälften.
 - Sortiere jede Hälfte rekursiv.
 - Verschmelze zwei Hälften zu einem sortierten Ganzen.

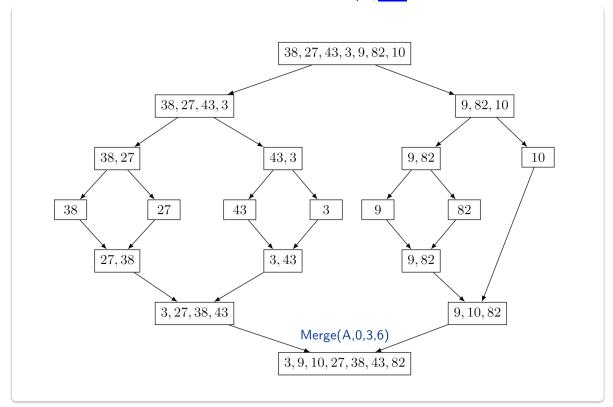


- Pseudocode:
 - Mergesort f
 ür ein Array A.
 - Sortiert den Bereich A[l] bis A[r].

```
\begin{aligned} & \mathsf{Mergesort}(\mathsf{A},l,r) \colon \\ & \mathbf{if} \ l < r \\ & \quad \mathsf{m} \leftarrow \lfloor (l+r)/2 \rfloor \\ & \quad \mathsf{Mergesort}(\mathsf{A},l,m) \\ & \quad \mathsf{Mergesort}(\mathsf{A},m+1,r) \\ & \quad \mathsf{Merge}(\mathsf{A},l,m,r) \end{aligned}
```

• Aufruf: Mergesort(A, 0, n-1) für ein Array A mit n Elementen.

Beispiel



Merging (Verschmelzen)

- Vorgehen: Verschmelze zwei sortierte Listen zu einer sortierten Gesamtliste.
- Wie kann man effizient verschmelzen?
 - Benutze temporäres Array.
 - Durchlaufe beide Listen vom Anfang an.
 - Führe die Elemente beider Listen im Reißverschlussverfahren zusammen, übernehme dabei jeweils das kleinste Element der beiden Listen.
 - Hat lineare Laufzeit.



• Pseudocode: Merge auf ein Array A. Verwendet Hilfsarray B.

```
Merge(A, l, m, r):
i \leftarrow l, j \leftarrow m+1, k \leftarrow l
while i \leq m und j \leq r
       if A[i] \leq A[j]
              B[k] \leftarrow A[i], i \leftarrow i+1
       else
              \mathsf{B}[k] \leftarrow \mathsf{A}[j], \ j \leftarrow j+1
       k \leftarrow k + 1
if i > m
       for h \leftarrow j bis r
              \mathsf{B}[k] \leftarrow \mathsf{A}[h], \ k \leftarrow k+1
else
       for h \leftarrow i bis m
              \mathsf{B}[k] \leftarrow \mathsf{A}[h], \ k \leftarrow k+1
for h \leftarrow l bis r
       A[h] \leftarrow B[h]
```

Eine nützliche Rekursionsgleichung

- Definition: C(n) = Anzahl der Schlüsselvergleiche (*comparisons*) in Mergesort bei einer Eingabegröße n.
- Mergesort Rekursion:

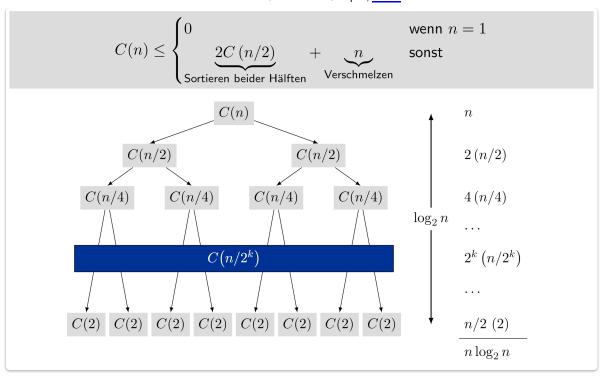
$$C(n) \leq \begin{cases} 0 & \text{wenn } n = 1 \\ \underbrace{C\left(\lceil n/2 \rceil\right)}_{\text{linke H\"{a}lfte}} + \underbrace{C\left(\lfloor n/2 \rfloor\right)}_{\text{rechte H\"{a}lfte}} + \underbrace{n}_{\text{Verschmelzen}} & \text{sonst} \end{cases}$$

- Lösung: $C(n) = O(n \log_2 n)$.
- Beweis: Wir beschreiben mehrere Wege das $O(n \log_2 n)$ zu beweisen.
- Annahmen:
 - Wir nehmen anfänglich an, dass n eine Zweierpotenz ist.
 - Für ein allgemeines n' mit $\frac{n}{2} < n' < n$ (wobei n eine Zweierpotenz ist) gilt dann:

$$C(n') = O(n \log n)$$

• da $O(\frac{n}{2}\log \frac{n}{2}) = O(n\log n)$ gilt.

Beweis durch Rekursionsbaum



Beweis durch Auflösen der Rekursion

Behauptung: Wenn C(n) die Rekursion erfüllt, dann $C(n) \leq n \log_2 n$.

$$C(n) \leq \begin{cases} 0 & \text{wenn } n = 1 \\ \underbrace{2C\left(n/2\right)}_{\text{Sortieren beider H\"{a}lften}} + \underbrace{n}_{\text{Verschmelzen}} & \text{sonst} \end{cases}$$

Beweis: Für n > 1:

$$\begin{split} \frac{C(n)}{n} &\leq \frac{2C(n/2)}{n} + 1 = \frac{C(n/2)}{n/2} + 1 \\ &\leq \frac{2C(n/4)}{n/2} + \frac{n/2}{n/2} + 1 = \frac{C(n/4)}{n/4} + 1 + 1 \\ &\leq \dots \\ &\leq \frac{C(n/n)}{n/n} + \underbrace{1 + \dots + 1}_{\log_2 n} \\ &= \log_2 n \end{split}$$

Beweis durch Induktion

Behauptung: Wenn C(n) die Rekursion erfüllt, dann $C(n) \leq n \log_2 n$.

$$C(n) \leq \begin{cases} 0 & \text{wenn } n = 1 \\ \underbrace{2C\left(n/2\right)}_{\text{Sortieren beider H\"{a}lften}} + \underbrace{n}_{\text{Verschmelzen}} & \text{sonst} \end{cases}$$

Beweis: (durch Induktion auf n)

- Induktionsanfang: n = 1.
- Induktionsbehauptung: $C(n) \le n \log_2 n$.
- Ziel: Zeige, dass $C(2n) \le 2n \log_2 2n$.

$$\begin{split} C(2n) & \leq 2C(n) + 2n \\ & \leq 2n \log_2 n + 2n \\ & = 2n(\log_2 n + 1) \\ & = 2n(\log_2(2n/2) + 1) \\ & = 2n(\log_2 2n - \log_2 2 + 1) \\ & = 2n(\log_2 2n - 1 + 1) \\ & = 2n \log_2 2n \end{split}$$

Analyse der Mergesort-Rekutsion

Behauptung: Wenn C(n) die folgende Rekursion erfüllt, dann $C(n) \leq n \lceil \log_2 n \rceil$.

$$C(n) \leq \begin{cases} 0 & \text{wenn } n = 1 \\ \underbrace{C\left(\lceil n/2 \rceil\right)}_{\text{linke H\"{a}lfte}} + \underbrace{C\left(\lfloor n/2 \rfloor\right)}_{\text{rechte H\"{a}lfte}} + \underbrace{n}_{\text{Verschmelzen}} & \text{sonst} \end{cases}$$

Beweis: (durch Induktion auf n)

- Induktionsanfang: n = 1.
- Definiere $n_1 = \lceil n/2 \rceil$, $n_2 = \lceil n/2 \rceil$.
- Induktionsschritt: Ist wahr für 1, 2, ..., n-1.

$$C(n) \leq C(n_1) + C(n_2) + n$$

$$\leq n_1 \lceil \log_2 n_1 \rceil + n_2 \lceil \log_2 n_2 \rceil + n$$

$$\leq n_1 \lceil \log_2 n_1 \rceil + n_2 \lceil \log_2 n_1 \rceil + n$$

$$= n \lceil \log_2 n_1 \rceil + n$$

$$\leq n \left(\lceil \log_2 n \rceil - 1 \right) + n$$

$$= n \lceil \log_2 n \rceil$$

$$n_1 = \lceil n/2 \rceil$$

$$\leq \lceil 2^{\lceil \log_2 n \rceil} / 2 \rceil$$

$$= 2^{\lceil \log_2 n \rceil} / 2$$

$$\Rightarrow \log_2 n_1 \leq \lceil \log_2 n \rceil - 1$$

- Asymptotische untere Schranke für C(n): Das Verschmelzen für n Elemente benötigt zumindest $C_{best} = \lfloor \frac{n}{2} \rfloor$ Schlüsselvergleiche.
- Daher gilt:

$$C_{best}(n) = C_{worst}(n) = C_{avg}(n) = \Theta(n \log n)$$

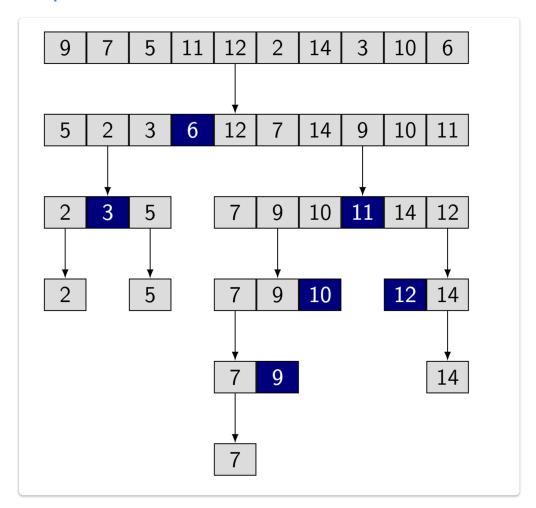
- Allgemein: Die Laufzeit von Mergesort wird durch die Anzahl der notwendigen Vergleiche dominiert.
- Daher gilt:

$$T_{best}(n) = T_{worst}(n) = T_{avo}(n) = \Theta(C(n)) = \Theta(n \log n)$$

Quicksort

- Quicksort: Benutzt auch das Divide-and-Conquer-Prinzip, aber auf eine andere Art und Weise.
- Teile: Wähle "Pivotelement" x aus Folge A, z.B. das an der letzten Stelle stehende Element. Teile A ohne x so in zwei Teilfolgen A_1 und A_2 , dass gilt:
 - A_1 enthält nur Elemente $\leq x$.
 - A_2 enthält nur Elemente $\geq x$.
- Herrsche:
 - Rekursiver Aufruf für A₁.
 - Rekursiver Aufruf für A_2 .
- Kombiniere: Bilde A durch Hintereinanderfügen von A_1 , x, A_2 .

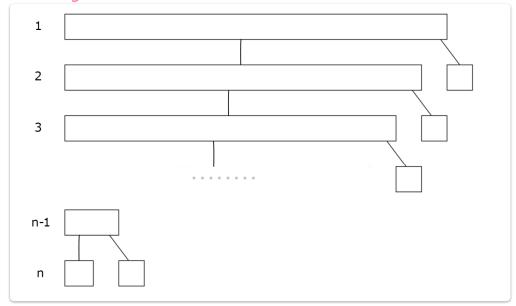
Beispiel



Analyse

- Best-Case:
 - Die beiden Teilfolgen haben immer (ungefähr) die gleiche Länge.
 - Die Höhe des Aufrufbaumes ist $\Theta(\log n)$.
 - Auf jeder Aufrufebene werden $\Theta(n)$ Vergleiche durchgeführt.
 - Die Anzahl der Vergleiche und die Laufzeit liegen in $\Theta(n \log n)$.

Worst-Case: Jede (Teil-)Folge wird immer beim letzten (oder immer beim ersten)
 Element geteilt.



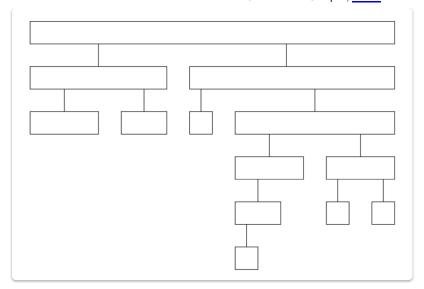
• Die Anzahl der Vergleiche ist $\Theta(n^2)$.

Worst-Case:

- Mögliches Szenario:
 - Aufsteigend sortierte Folge und es wird immer das hinterste Element als Pivotelement gewählt.
 - Alle restlichen Elemente sind kleiner als das Pivotelement und daher wird die Rekursion nur für die linke Seite (alle restlichen Elemente außer dem Pivotelement) weitergeführt. Die rechte Seite ist leer (Terminierung der Rekursion).
 - Die Größe der Teilfolge in der nächsten Rekursionsstufe verringert sich immer nur um 1!
 - $\Theta(n)$ rekursive Aufrufe.
 - Die Laufzeit liegt in $\Theta(n^2)$.
 - Der zum Array zusätzlich benötigte Speicherplatz ist durch die $\Theta(n)$ rekursiven Aufrufe ebenfalls $\Theta(n)$.
- "Vermeiden" des Worst-Case in der Praxis:
 - Pivotelement immer zufällig wählen.
 - Randomisierter Quicksort.
 - Es ist nicht mehr die sortierte Folge das Worst-Case-Szenario.
 - Betrachte jeweils das erste, letzte und mittlere Element (an der Position $\lfloor \frac{n}{2} \rfloor$) und nimm den Median als Pivotelement.

Average-Case:

- Komplizierter Beweis zeigt, dass die Anzahl der Vergleiche und die Laufzeit dafür auch in $\Theta(n \log n)$ liegen.
- Beispiel für Average-Case: Jede (Teil-)Liste wird nahe der Mitte geteilt.



• Die Anzahl der Vergleiche ist $\Theta(n \log n)$.

Speicherplatzkomplexität

- Speicherplatzkomplexität: Ist ein Maß für das Anwachsen des Speicherbedarfs eines Algorithmus in Abhängigkeit von der Eingabegröße.
- Beispiele für Speicherplatzkomplexität:
 - Quicksort: Worst-Case liegt in $\Theta(n)$, Best-/Average-Case liegt in $\Theta(\log n)$.
 - Mergesort: Best-/Average-/Worst-Case liegt in $\Theta(n)$.
- Praxis: In der Praxis wird daher Quicksort sehr oft Mergesort vorgezogen.

Vergleich von Sortierverfahren

Tabelle: Laufzeit und Vergleiche.

Sortierverfahren	Best-Case	Average-Case	Worst-Case
Insertionsort	$\Theta(n)$	$\Theta(n^2)$	$\Theta(n^2)$
Selectionsort	$\Theta(n^2)$	$\Theta(n^2)$	$\Theta(n^2)$
Mergesort	$\Theta(n \log n)$	$\Theta(n \log n)$	$\Theta(n \log n)$
Quicksort	$\Theta(n \log n)$	$\Theta(n \log n)$	$\Theta(n^2)$

Tabelle: Zusätzlicher Speicher.

Sortierverfahren	Best-Case	Average-Case	Worst-Case
Insertionsort	$\Theta(1)$	$\Theta(1)$	$\Theta(1)$
Selectionsort	$\Theta(1)$	$\Theta(1)$	$\Theta(1)$
Mergesort	$\Theta(n)$	$\Theta(n)$	$\Theta(n)$
Quicksort	$\Theta(\log n)$	$\Theta(\log n)$	$\Theta(n)$

Einsatz von Sortierverfahren

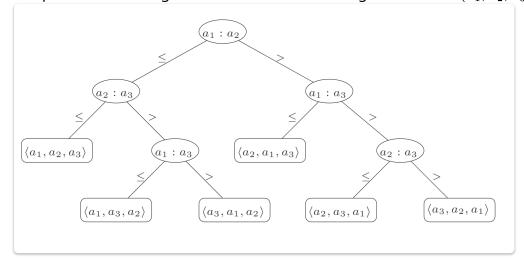
- Quicksort:
 - Wird sehr oft in allgemeinen Sortiersituationen bevorzugt.
- Mergesort:
 - Mergesort wird hauptsächlich für das Sortieren von Listen verwendet.
 - Wird auch für das Sortieren von Dateien auf externen Speichermedien eingesetzt.
 - Dabei wird aber eine iterative Version von Mergesort (Bottom-up-Mergesort) verwendet, bei der nur $\log n$ -mal eine Datei sequentiell durchgegangen wird.

Eine untere Schranke

- Ausgangslage: Wir haben verschiedene Sortieralgorithmen kennengelernt. Die Worst-Case Laufzeit liegt im Bereich $O(n \log n)$ bis $O(n^2)$.
- Frage: Geht es besser als in $O(n \log n)$ Zeit, z.B. O(n)?
- Antwort: Wir zeigen für das allgemeine Sortierproblem unter der Annahme, dass n verschiedene Schlüssel sortiert werden müssen, dass $O(n \log n)$ optimal ist.

Entscheidungsbaum

- Entscheidungsbaum:
 - Die Knoten entsprechen einem Vergleich von Elementen a_i und a_i .
 - Die Blätter entsprechen den Permutationen.
- Beispiel: Entscheidungsbaum des Insertionsort Algorithmus für (a_1, a_2, a_3) .



- Anzahl der Schlüsselvergleiche: Die Anzahl der Schlüsselvergleiche im Worst-Case C_{worst} entspricht genau der Anzahl der Knoten auf dem längsten Pfad von der Wurzel bis zu einem Blatt minus 1.
- Frage: Wie lautet die untere Schranke für die Höhe eines Entscheidungsbaums?
- Satz: Jeder Entscheidungsbaum für die Sortierung von n paarweise verschiedenen Schlüsseln hat die Höhe $\Omega(n\log_2 n)$.

Beweis

Beweis:

- Betrachte einen Entscheidungsbaum der Höhe *h*, der *n* unterschiedliche Schlüssel sortiert.
- Der Baum hat mindestens n! Blätter.
- $n! \leq 2^h$, das impliziert $h \geq \log_2(n!)$.
- Hilfsrechnung: $n! \ge n \cdot (n-1) \cdot (n-2) \cdots \lceil \frac{n}{2} \rceil \ge (\lceil \frac{n}{2} \rceil)^{\lceil \frac{n}{2} \rceil} \ge \frac{n}{2}^{\frac{n}{2}}$
- $h \ge \log_2(n!) \ge \log_2\left(\frac{n^{\frac{n}{2}}}{2}\right) \ge \frac{n}{2}\log_2\frac{n}{2} = \frac{n}{2}(\log_2 n 1) = \Omega(n\log_2 n)$

Untere Schranke für allgemeines Sortierproblem

- Satz: Jedes allgemeine Sortierverfahren benötigt zum Sortieren von n paarweise verschiedenen Schlüsseln mindestens $\Omega(n \log n)$ Laufzeit im Worst-Case.
- Folgerung: Mergesort ist ein asymptotisch *zeitoptimaler* Sortieralgorithmus. Es geht (asymptotisch) nicht besser!

Lineare Sortierverfahren

- Beobachtung: Das Ergebnis für die untere Schranke basiert auf der Annahme, dass man keine Eigenschaften der zu sortierenden Elemente ausnutzt, sondern lediglich den Vergleichsoperator.
- Praxis: Tatsächlich sind aber meist Wörter über ein bestimmtes Alphabet (d.h. einer bestimmten Definitionsmenge) gegeben, z.B.:
 - Wörter über $\{a, b, \ldots, z, A, B, \ldots, Z\}$.
 - Dezimalzahlen.
 - Ganzzahlige Werte aus einem kleinen Bereich.
- Lineare Sortierverfahren: Diese Information über die Art der Werte und ihren Wertebereich kann man zusätzlich ausnutzen und dadurch im Idealfall Verfahren erhalten, die auch im Worst-Case in linearer Zeit sortieren.

Beispiel: Countsort

Eingabe: n Zahlen im Bereich 0 bis z im Array A, Hilfsarray Counts, z < n

Komplexität: Erste Schleife in $\Theta(z)$, zweite Schleife in $\Theta(n)$, dritte (mit vierter) Schleife kann nur maximal n Zahlen bearbeiten und ist daher auch in $\Theta(n)$. Damit läuft der Algorithmus in $\Theta(z+n+n)=\Theta(n)$ (da z=O(n)).

Beispiele zu Divide and Conquer:

Gute Beispiele für dieses Prinzip findet man in den Slides ab Seite 54.

Da hätte man ein mal Inversionen zählen und dann noch Closest Pair of Points