8. Praktische Datenstrukturen

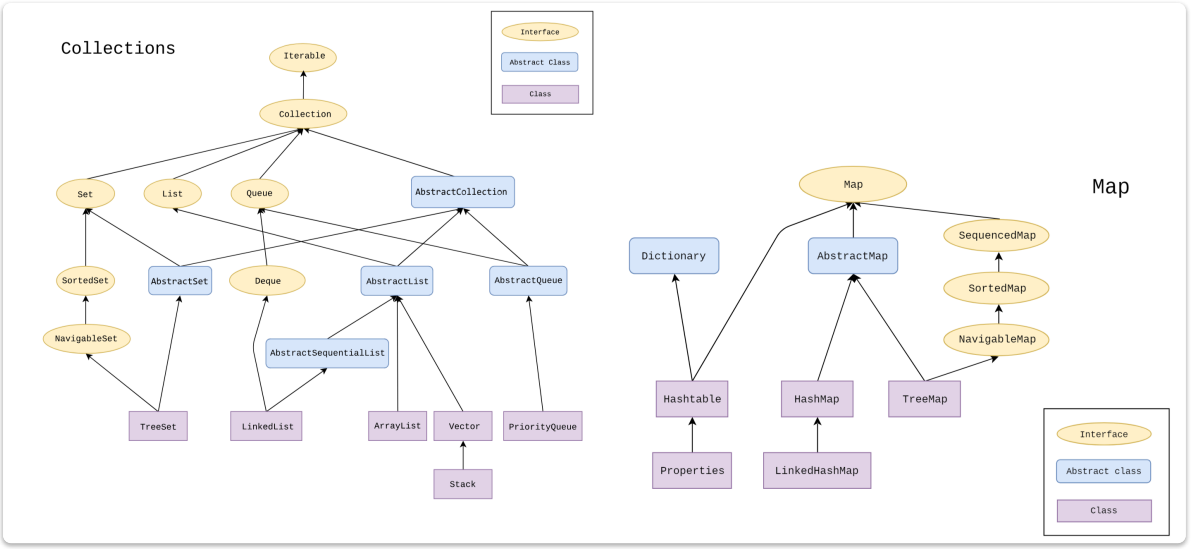

Interfaces

- Für unterschiedliche Datenstrukturen.
- Schnittstellen für den Zugriff auf die Datenstrukturen.
- Konkrete Implementierungen realisieren diese Interfaces.

Collection:

- Eine Collection verwaltet Objekte (Elemente).
- Interface enthält generelle Methoden (für alle Collection-Typen).
- Es gibt keine direkte Implementierung dieses Interfaces.

Set:

- Eine Collection, die keine Duplikate enthält.

List:

- Eine geordnete Collection (die Duplikate enthalten kann).
- Elemente können über einen Index angesprochen werden (nicht immer effizient).

Queue/Deque:

- Verwalten von Warteschlangen.
- FIFO, Prioritätswarteschlangen.
- Einfügen und Löschen an beiden Enden bei Deque („double ended queue“).

Map:

- Maps verwalten Schlüssel mit dazugehörigen Werten.

SortedSet und SortedMap:

- Sind spezielle Versionen von Set und Map, bei denen die Elemente (Schlüssel) in aufsteigender Reihenfolge verwaltet werden.

	Interface				
Konzept	Set	List	Queue	Deque	Map
Arrays	–	ArrayList	–	ArrayDeque	–
Bäume	TreeSet	–	–	–	TreeMap
Hashtabellen	HashSet	–	–	–	HashMap
Heap	–	–	PriorityQueue	–	–
Verkettete Listen	–	LinkedList	LinkedList	LinkedList	–

Listenimplementierung

Listen

ArrayList:

- Indexzugriff auf Elemente ist überall gleich schnell ($O(1)$).
- Einfügen und Löschen ist am Listenende schnell und wird mit wachsender Entfernung vom Listenende langsamer ($O(n)$).

LinkedList:

- Indexzugriff auf Elemente ist an den Enden schnell und wird mit der Entfernung von den Enden langsamer ($O(n)$).
- Einfügen und Löschen ohne Indexzugriff ist überall gleich schnell ($O(1)$).

Queue

LinkedList ist auch eine Implementierung von Queue.

PriorityQueue:

- Ist als Min-Heap implementiert.
- Einfügen eines Elements und Löschen des ersten Elements in einer Queue der Größe n sind in $O(\log n)$.
- Löschen eines beliebigen Elements aus einer Queue der Größe n ist in $O(n)$.
- Lesen des ersten Elements in einer Queue ist in konstanter Zeit möglich ($O(1)$).

Beispiel zu ArrayList, LinkedList und PriorityQueue

```java
import java.util.*;

public class Example {
    public static void main(String[] args) {
        List<Integer> myAL = new ArrayList<>();
        myAL.add(42); myAL.add(17);
        System.out.println(myAL); // [42, 17]

        List<Integer> myLL = new LinkedList<>();
        myLL.add(42); myLL.add(17);
        System.out.println(myLL); // [42, 17]

        PriorityQueue<Integer> myPQ = new PriorityQueue<>();
        myPQ.add(750);
        myPQ.add(500);
        myPQ.add(900);
        myPQ.add(100);

        while (!myPQ.isEmpty()) {
            System.out.print(myPQ.remove() + " ");
        } // 100 500 750 900
    }
}
```

TreeSet und HashSet

Set-Implementierungen: TreeSet

TreeSet:

- Implementiert als Rot-Schwarz-Baum.
- `null`-Elemente sind nicht erlaubt.
- Die Laufzeit von Einfügen, Suchen und Löschen eines Elements liegt bei einem Baum mit n Elementen in $O(\log n)$.
- Auf die Elemente eines `TreeSets` muss eine Ordnung definiert sein (müssen vergleichbar sein, d.h. das Interface `Comparable` implementieren).

Rot-Schwarz-Baum:

- Variante eines balancierten Suchbaums.
- Kann als Spezialfall eines B-Baums der Ordnung 4 betrachtet werden.
- Einfügen und Löschen ist effizienter als in B-Bäumen solange die Datenmenge nicht zu groß ist.
- Selbstbalancierender binärer Suchbaum: jeder Knoten entweder rot oder schwarz.
- Die Wurzel ist schwarz. Jeder Blattknoten (NIL) ist schwarz.
- Kindknoten von einem roten Knoten sind schwarz.
- Für jeden Knoten gilt, dass alle Pfade von diesem Knoten zu nachfolgenden Blattknoten die gleiche Anzahl an schwarzen Knoten beinhalten.
- Einfügen und Löschen können eine Rebalancierung erfordern.

Beispiel:

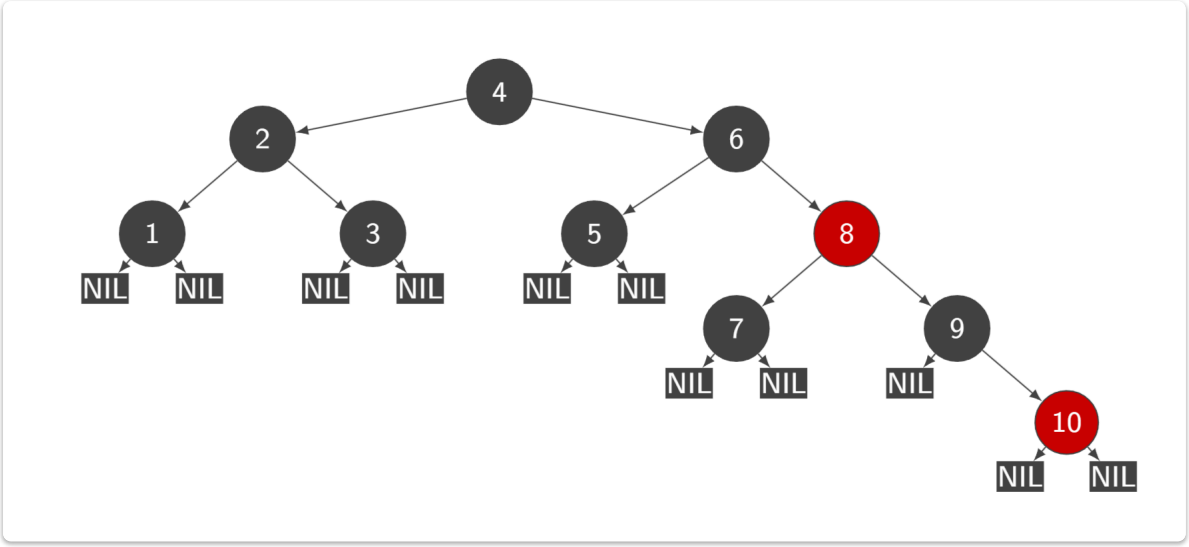

Set-Implementierungen: HashSet

HashSet:

- `null`-Elemente sind zulässig.
- Einfügen, Suchen und Löschen sind in konstanter Zeit möglich (abhängig von der Verteilung der Einträge in der Hashtabelle).
- Aber: Rehashing kann zu Performance-Problemen führen (siehe auch API-Beschreibung).

Implementierung:

- Hashing mit Verkettung der Überläufer. Falls die Liste zu lange wird, wird sie in eine `TreeMap` umgewandelt.
- Maximaler Belegungsfaktor = 0.75.
- Bei Überschreitung des Belegungsfaktors verdoppelt sich die Größe. (Größe der Hashtabelle ist immer eine Zweierpotenz).

Beispiel zu Treeset und Hashmap

```
import java.util.*;

public class Example {
    public static void main(String[] args) {
        Set<String> myTS = new TreeSet<>();
        myTS.add("apples");
        myTS.add("bananas");
        myTS.add("strawberries");
        myTS.add("grapes");
        myTS.add("strawberries"); // adding duplcate elements will be ignored
        System.out.println(myTS); // [apples, bananas, grapes, strawberries]

        Set<String> myHS = new HashSet<>();
        myHS.add("apples");
        myHS.add("bananas");
        myHS.add("strawberries");
        myHS.add("grapes");
        myHS.add("strawberries"); // adding duplcate elements will be ignored
        System.out.println(myHS); // [strawberries, bananas, apples, grapes]
    }
}
```

Verschiedene Implementierungen von Hashing

mehr siehe hier

Beispiele für Verkettung der Überläufer:

	Belegungsfaktor	Wachstumsfaktor	Tabellengröße
Java	0.75	2	Zweierpotenzen
C++	1	>2	Primzahlen
Go	6.5	2	Zweierpotenzen

Beispiele für offenes Hashing:

	Belegungsfaktor	Wachstumsfaktor	Tabellengröße	Sondierung
Python	0.66	2	Zweierpotenzen	Quadratisch
Ruby	0.5	2	Zweierpotenzen	Quadratisch

Anmerkung: Die Sondierungsfunktion verwendet in beiden Fällen zusätzlich eine sogenannte Perturbation.

Maps

- Maps sind eine Verallgemeinerung von Arrays mit einem beliebigen Indextyp (nicht nur `int`).
- Eine Map ist eine Menge von Schlüssel-Werte Paaren.
  - Schlüssel müssen innerhalb einer Map eindeutig sein.
  - Werte müssen nicht eindeutig sein.

Arten von Maps: Wie bei Sets gibt es grundsätzlich zwei Versionen.

- HashMap: Implementierung wie HashSet.
- TreeMap: Implementierung wie TreeSet.

Anmerkung: Genau genommen sind Tree- und HashMap die primitiven Implementierungen die von Tree- und HashSet verwendet werden.

Operationen auf Maps: Bestimmte Methoden wie z.B. `put`, `get`, `containsKey`, `containsValue`, `remove` etc. werden angeboten.

Beispiele zu HashMap und TreeMap

```
import java.util.*;

public class Example {
    public static void main(String[] args) {
        // HashMap Beispiel
        Map<String, Integer> myHM = new HashMap<>();
        myHM.put("one", 1);
        myHM.put("two", 2);
        myHM.put("three", 3);
        myHM.put("four", 4);
        myHM.put("five", 5);
        // only add if key does not exist or is mapped to `null`

        System.out.println("myHM: " + myHM);
        // {one=1, two=2, three=3, four=4, five=5}

        String id = "three";
        if (myHM.containsKey(id)) {
            System.out.println("Found key " + id + ". Value: " + myHM.get(id));
            // Found key three. Value: 3
        }

        // TreeMap Beispiel
        Map<String, Integer> myTM = new TreeMap<>();
```

```
        myTM.put("one", 1);
        myTM.put("two", 2);
        myTM.put("three", 3);
        myTM.put("four", 4);
        myTM.put("five", 5);
        // only add if key does not exist or is mapped to `null`

        System.out.println("myTM: " + myTM);
        // {five=5, four=4, one=1, three=3, two=2} (sortiert nach Schlüssel)

        id = "four";
        if (myTM.containsKey(id)) {
            System.out.println("Found key " + id + ". Value: " + myTM.get(id));
            // Found key four. Value: 4
        }
    }
}
```

Abstrakte Klassen

- Unterstützen die Entwicklung neuer Klassen im Framework.
- Implementieren einen Teil eines Interfaces und lassen bestimmte Teile noch offen.

Neue Klasse implementieren:

- Auswählen einer geeigneten abstrakten Klasse von der geerbt wird.
- Implementierung aller abstrakten Methoden.
- Sollte die Collection modifizierbar sein, dann müssen auch einige konkrete Methoden überschrieben werden (siehe API).
- Testen der neuen Klasse (inklusive Performance).

Beispiele:

- `AbstractCollection`
- `AbstractSet`
- `AbstractList` (basierend auf Array)
- `AbstractSequentialList` (basierend auf verketteter Liste)
- `AbstractQueue`
- `AbstractMap`

API: API-Dokumentation jeder abstrakten Klasse beschreibt genau, wie man eine Klasse ableiten muss:

- Grundlegende Implementierung.
- Welche Methoden müssen implementiert werden.
- Welche Methoden müssen überschrieben werden, wenn man Modifikationen zulassen möchte.

Algorithmen im Collections-Framework

Algorithmen:

- Das Collections-Framework bietet auch Algorithmen für die Verarbeitung von Container-Klassen an.
- Diese Algorithmen werden als statische Methoden (polymorphe Methoden) in der Hilfsklasse `Collections` gesammelt.

Beispiele:

- `sort` sortiert die Elemente einer generischen Liste nach aufsteigender Größe.
- `binarySearch` sucht ein Element in der sortierten Liste (Voraussetzung) und liefert einen Index zurück, wenn das Element gefunden wurde (ansonsten eine negative Zahl).
- `max` liefert das größte Element einer Collection.
- `shuffle` mischt die Elemente einer generischen Liste zufällig.

Beispiele zu Algorithmen im Collections-Framework

```
import java.util.*;

public class Example {
    public static void main(String[] args) {
        List<Integer> myAL = new ArrayList<>(Arrays.asList(5, 3, 1, 4));
        System.out.println("myAL: " + myAL); // [5, 3, 1, 4]

        Collections.sort(myAL);
        System.out.println("sort(myAL): " + myAL); // [1, 3, 4, 5]

        System.out.println("Collections.max(myAL): " + Collections.max(myAL)); //
5
        System.out.println("Collections.binarySearch(myAL, 3): "
            + Collections.binarySearch(myAL, 3)); // 1
        System.out.println("Collections.binarySearch(myAL, 42): "
            + Collections.binarySearch(myAL, 42)); // -5

        Collections.shuffle(myAL);
        System.out.println("shuffle(myAL): " + myAL); // z.B.: [1, 4, 3, 5]
    }
}
```

Timsort

- Zum Sortieren von Collections wird Timsort verwendet.
- Timsort ist eine Kombination von Mergesort und Insertionsort.
- Timsort wurde 2002 von Tim Peters für die Verwendung in Python entwickelt.
- Heute wird Timsort unter anderem in Python, Java, Android Plattform, V8 (Chrome Browser), Swift, Rust verwendet.

Grundlegende Idee: Finde schon sortierte Stücke (Runs) des Inputs S, die dann paarweise verschmelzt werden (Merging).

```
Timsort(S)
runs ← partitioniere S in Runs
R ← leerer Stack
while runs ≠ ∅
    entferne Run r von runs and pushe r auf den Stack R
    merge_collapse(R) // ausbalanciertes Verschmelzen
while height(R) ≠ 1
    verschmelze die beiden oberen Runs am Stack
```

Berechnen von Runs

Min_Run:

- Runs sind mindestens `Min_Run` lang.
- `Min_Run` wird so gewählt, dass $\frac{\text{Größe des Arrays}}{\text{Min\_Run}}$ eine Zweierpotenz oder etwas kleiner als eine Zweierpotenz ist.
- Experimente zeigen, dass ein Wert zwischen 32 und 64 für `Min_Run` optimal ist.

Finden von Runs:

- Startend bei dem ersten Element, das noch nicht in einem Run ist, füge so lange Elemente zum Run hinzu, wie die Sequenz entweder aufsteigend oder strikt absteigend ist.
- Falls die Sequenz strikt absteigend war, invertiere die Reihenfolge der Elemente.
- Falls die Länge der Sequenz größer `Min_Run` ist, ist damit ein Run gefunden.
- Andernfalls füge solange nachfolgende Elemente hinzu bis `Min_Run` erreicht ist. Sortiere den entstandenen Run mittels (binärem) Insertionsort.

Runs mit Min_Run = 4:

Verschmelzen der Runs (Merging)

- Nachdem das Array in Runs aufgeteilt und diese sortiert sind, werden diese wie bei Mergesort verschmolzen.

- Merging ist am effizientesten, wenn die Anzahl der Runs eine Zweierpotenz ist und die Runs möglichst gleich groß sind.
- Da Runs im Allgemeinen sehr unterschiedliche Größen haben können, wird versucht mithilfe von Invarianten eine sinnvolle Merge-Reihenfolge zu finden. Beachte dabei nur "benachbarte" Runs werden verschmolzen.
- Zusätzlich wird beim Merging eine Strategie namens Galloping verwendet, um möglicherweise vorhandene Strukturen in den Runs zu nutzen.

Invarianten und merge_collapse

- Stack R von Runs mit Aufbau $R[1], \ldots, R[height(R)]$, wobei $R[1]$ top-of-stack ist.
- Die Länge von Run $R[i]$ wird mit r_i bezeichnet.

```
merge_collapse(R)
while height(R) > 1
    if height(R) > 2 und r_3 ≤ r_2 + r_1
        if  r_3 < r_1
            verschmelze R[2] und R[3] am Stack
        else
            verschmelze R[1] und R[2] am Stack
    elseif height(R) > 1 und r_2 ≤ r_1
        verschmelze R[1] und R[2] am Stack
    else break
```

- Nach Ausführung von `merge_collapse(R)` gelten folgende Invarianten:
  - (1) $r_2 > r_1$
  - (2) $r_3 > r_1 + r_2$

Beispiel zu Invarianten

- Wiederholung Invarianten: (1) $r_2 > r_1$, (2) $r_3 > r_1 + r_2$
- Länge der Runs am Stack werden in Reihenfolge ..., r_3, r_2, r_1 angegeben.
- Stack mit Arrays der Größe: 138, 67, 15. Invarianten erfüllt.
- Nächster Run hat Größe 16. D.h. 138, 67, 15, 16. Invariante (2) nicht erfüllt!
- Mergen ergibt: 138, 67, 31. Invarianten erfüllt.
- Nächster Run hat Größe 17. D.h. 138, 67, 31, 17. Invariante (1) nicht erfüllt.
- Nächster Run hat Größe 15. D.h. 138, 67, 31, 17, 15. Invariante (1) nicht erfüllt!
- Mergen ergibt: 138, 67, 31, 32. Invariante (2) nicht erfüllt!
- Mergen ergibt: 138, 67, 63. Invarianten erfüllt.
- ...

Galloping

- Lineares Merging:
  - Arrays A und B sollen verschmolzen (gemerged) werden.
  - Vergleiche $A[0]$ und $B[0]$ und verschiebe den kleineren Wert in das Merge-Array.

- Ineffizient falls das selbe Array gewinnt.
- Timsort speichert, wie oft dasselbe Array gewinnt und wechselt in den Galloping-Mode falls dasselbe Array mal gewinnt.

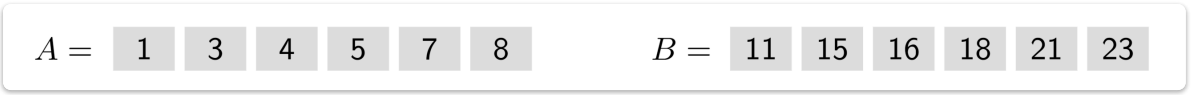

- Galloping:
  - Falls A Min-Galloping gewonnen hat, suche das erste Element $A[i]$ in A das größer als $B[0]$ ist.
  - Kopiere $A[0]$ bis $A[i-1]$ in das Merge-Array.
  - Suche nach $B[j]$ mittels galoppierender binärer Suche, d.h. vergleiche $B[0]$ mit $A[1], A[3], A[7], \ldots, A[2^k - 1]$ bis $B[0]$ kleiner ist, dann binäre Suche.

Vorteile und Nachteile von Timsort

- Vorteile:
  - Extrem schnell auf Arrays, die bereits viel Struktur haben (Best-Case: $O(n)$).
  - Average- und Worst-Case $O(n \log n)$ wie Mergesort.
  - Im Durchschnitt weniger Objekt-Vergleiche als Quicksort.
  - Stabil.
- Nachteile:
  - Zusätzlicher Speicher: Average- und Worst-Case: $O(n)$.
  - (Optimierter Quicksort: $O(\log n)$)
  - Im Durchschnitt langsamer als ein optimierter Quicksort, wenn das Vergleichen von Elementen sehr effizient möglich ist.
- Kompromisslösung in Java: Timsort wird nur auf Objekt-Arrays verwendet. Für das Sortieren von Arrays mit primitiven Datentypen (z.B. int) ist eine spezielle Quicksort Variante als Sort in der Hilfsklasse Arrays vorgesehen.

Sortieren: Stabilität (Wiederholung)

- Definition: Ein Sortierverfahren ist stabil, wenn es die Reihenfolge der Datensätze, deren Sortierschlüssel gleich sind, bewahrt.

  Beispiel: Liste von Personendaten mit Abteilungsnummer (innerhalb der Abteilung sortiert): 3 - Daniel, 4 - Maria, 2 - Paul, 3 - Erika, 1 - Anton, 3 - Sarah
  - Sortierung nach Abteilungsnummer mit stabilem Sortierverfahren:
    1 - Anton, 2 - Paul, 3 - Daniel, 3 - Erika, 3 - Sarah, 4 - Maria
  - Beispiel Sortierung nach Abteilungsnummer mit instabilem Sortierverfahren:
    1 - Anton, 2 - Paul, 3 - Sarah, 3 - Daniel, 3 - Erika, 4 - Maria

Stabilität: Insertionsort

Insertionsort ist stabil.

Zur Erinnerung:

```
Insertionsort(A):
for i ← 1 bis n − 1
    key ← A[i], j ← i − 1
    while j ≥ 0 und A[j] > key
        A[j + 1] ← A[j]
        j ← j − 1
    A[j + 1] ← key
```

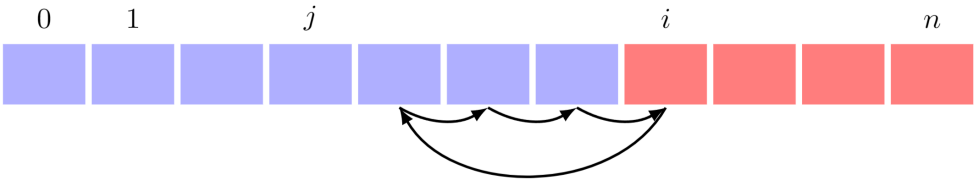

Stabilität: Insertionsort

Mergesort ist stabil.

Idee: Beim Aufteilen linke Hälfte nach links, rechte nach rechts, d.h. Reihenfolge wird nicht geändert. Beim Verschmelzen wird bei Gleichheit das linke Element genommen und daher die Reihenfolge auch nicht geändert.
Beispiel zur Illustration der Idee (kein Beweis) mit vereinfachter Ausgangssequenz 3 4 2 3 1 3

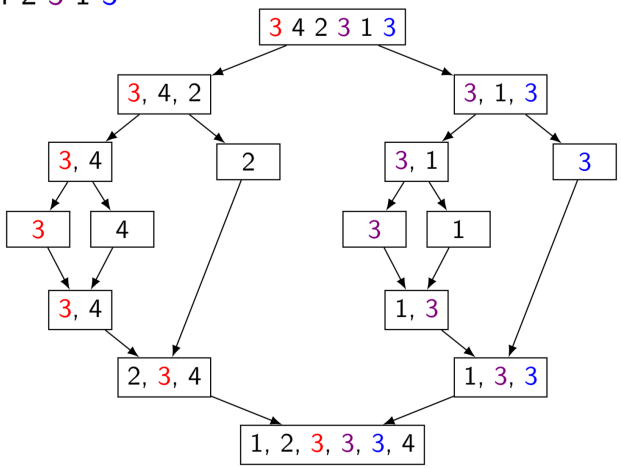

Stabilität Selectionsort

Selectionsort ist nicht stabil.

Beispiel mit vereinfachter Ausgangssequenz 3 4 2 3 1 3

3 4 2 3 1 3

1 4 2 3 3 3

1 2 4 3 3 3

1 2 3 4 3 3

1 2 3 3 4 3

1 2 3 3 3 4

Zur Erinnerung:

```
Selectionsort(A):
for i ← 0 bis n − 2
    smallest ← i
    for j ← i + 1 bis n − 1
        if A[j] < A[smallest]
            smallest ← j
    Vertausche A[i] mit A[smallest]
```

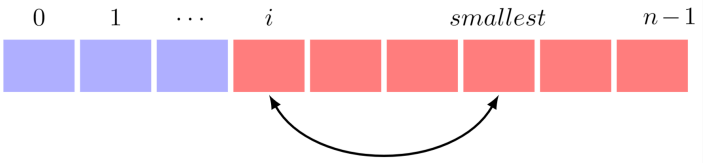

Weitere Bibleotheken

Eclipse Collections

- https://www.eclipse.org/collections/
- Optimierte Sets und Maps, Immutable Collections, Collections für primitive Datentypen, Multimaps, Bimaps, Verschiedene Iterationsstile

Google Guava

- https://github.com/google/guava
- Unterstützt z.B. Multisets, Multimaps, Bimaps

Apache Commons Collections

- https://commons.apache.org/proper/commons-collections/

Brownies Collections

- http://www.magicwerk.org/page-collections-overview.html
- z.B. High Performance Listen (GapList, BigList)

JGraphT

- https://github.com/jgrapht/jgrapht
- Algorithmen und Datenstrukturen für Graphen