

# 8. Bildmerkmale - Interest Points

Quellen:

- [EVC\\_Skriptum\\_CV, p.40](#) bis [EVC\\_Skriptum\\_CV, p.45](#)
- 

## Interessenspunkte (Interest Points)

### Definition

- Interessenspunkte sind charakteristische Punkte in einem Bild.
- Sie dienen der Beschreibung und dem Matching (Abgleich) von Bildern.

### Eigenschaften

- Hervorstechend durch **einzigartige und unterscheidbare Merkmale**
- Basieren auf **lokalen Intensitätsunterschieden**, z. B.:
  - Ecken
  - Kanten
  - Strukturen

### Zweck

- Werden zur **Bildbeschreibung** verwendet
  - Besonders geeignet für **Vergleiche und Wiedererkennung** zwischen Bildern
- 

## Harris Corner Detection

### Allgemeines

- Harris Corner Detection ist ein verbreiteter Algorithmus zur **Eckendetektion** in Bildern.
- Ziel: **Identifikation von Interessenspunkten**, die Ecken darstellen.

### Kernidee

- Berechnung der **Harris-Matrix**  $M$ :

$$M = \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}$$

- $I_x, I_y$  sind die **Ableitungen des Bildes** entlang der x- bzw. y-Achse.

## Harris Response-Funktion

- Dient zur Bewertung der Matrix  $M$  an jedem Pixel:

$$R = \det(M) - k \cdot (\text{tr}(M))^2$$

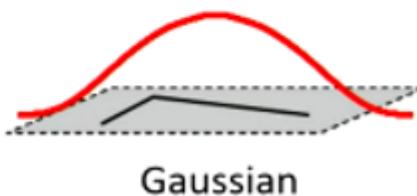
- $\det(M)$ : Determinante von  $M$
- $\text{tr}(M)$ : Spur von  $M$  (Summe der Diagonaleinträge)
- $k$ : Empirischer Parameter (typisch  $0,04 \leq k \leq 0,06$ )

## Eckendetektion

- Für **jeden Pixel** im Bild wird  $R$  berechnet.
- Ein Pixel wird als **potenzielle Ecke** klassifiziert, wenn:
  - $R$  ist größer als ein **vorgegebener Schwellenwert**

$$w(x, y) = \exp\left(-\frac{(x^2 + y^2)}{2\sigma^2}\right)$$

Window function  $w(x, y) =$



## SIFT (Scale-Invariant Feature Transform)

### Allgemeines

- SIFT ist ein Verfahren zur **Detektion und Beschreibung lokaler Merkmale** in Bildern.
- Besonders **robust gegenüber**:
  - Skalierung
  - Rotation
  - Helligkeitsänderungen

### Ablauf des Algorithmus

- Besteht aus mehreren Schritten wie der Skalenraumextrema-Detektion, Keypoint lokalisierung und Deskriptionsextraktion

# SURF (Speeded-Up Robust Features)

## Allgemeines

- SURF ist eine Weiterentwicklung von SIFT
- Ziel: Schnellere und effizientere Berechnung lokaler Merkmale

## Eigenschaften

- Robust gegenüber:
  - Skalierung
  - Rotation
  - Helligkeitsänderungen

## Technische Unterschiede zu SIFT

- Haar Wavelet-Responses werden zur Merkmalserkennung verwendet:
    - Vereinfachen und beschleunigen die Berechnungen
    - Geringerer Rechenaufwand bei vergleichbarer Robustheit
  - SURF ist im Vergleich zu SIFT schneller, insbesondere bei großen Bildmengen oder Echtzeitanwendungen
- 

# Bildmerkmale

## Definition

- Bildmerkmale sind mathematische Beschreibungen eines Bildes oder seiner Teile.
- Ziel: Repräsentation von Informationen, die besser unterscheidbar und nützlicher als reine Pixelwerte sind.
- Unterstützen die Extraktion relevanter Informationen für verschiedene Anwendungen.

## Arten von Bildmerkmalen

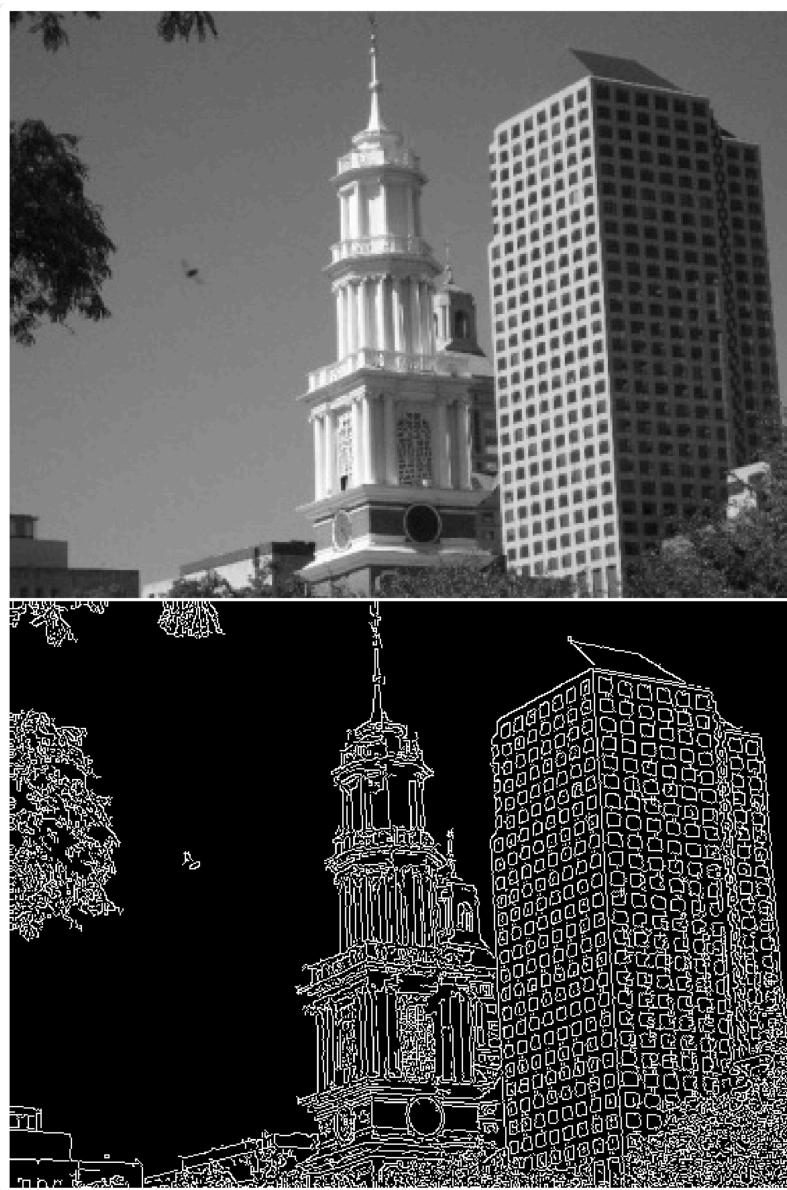
- Globale Merkmale:
  - Beschreiben das gesamte Bild
  - Beispiel: Grauerthistogramm
  - Nachteile:
    - Schlecht unterscheidbar
    - Nicht robust genug für komplexe Anwendungen
- Lokale Merkmale:
  - Beschreiben kleine Bildregionen

- Ziel: Mathematische Beschreibung von **interessanten Bildbereichen** und ihrer lokalen Nachbarschaft
- Robust gegenüber Skalierung, Rotation, etc.
- Anwendungen:
  - **Bildregistrierung**
  - **Panorama-Stitching**
  - **3D-Modellierung**
  - **Objekterkennung**

## Schritte der Merkmalsextraktion

### 1. Merkmalsdetektion

- Identifikation von **Bildbereichen mit hohem Informationsgehalt**
  - Bestimmung der **räumlichen Lage und Skalierung**
  - Ergebnis: **Interest Points / Keypoints**
- ### 2. Merkmalsbeschreibung
- Erstellung eines **Merkmalsvektors**, der die **lokale Bildstruktur** beschreibt
  - Die Gesamtheit aller Vektoren definiert den **Merkmalsraum** (engl. *feature space*)



## Kantenerkennung

mehr siehe [6. Kantenfilterung](#)

### Bedeutung von Kanten

- Kanten enthalten **nicht redundante** Informationen eines Bildes.
- Sie stellen **Unstetigkeiten** in der Helligkeit dar – also **starke Helligkeitsveränderungen**.

### Ziel der Kantendetektion

- Finden von **Punkten mit plötzlichen Intensitätsänderungen** im Bild.
- Ergebnis: **Menge von Pixeln**, an denen sich **Unstetigkeitsstellen** befinden.

### Vorteile

- **Reduktion der Datenmenge**:

- Unwichtige, redundante Informationen werden **herausgefiltert**
- Nur die **strukturell relevanten Bildinformationen** (hohe Frequenzen) bleiben erhalten

## Einschränkungen

- **Nicht rotationsinvariant**
  - **Nicht skalierungsinvariant**
  - Dadurch sind gleiche Merkmale in unterschiedlichen Bildern **schwer vergleichbar**
- 

# Interest Points

## Eigenschaften von Eckpunkten

- **Auffällige Bildstellen** – sowohl für Menschen als auch für Algorithmen



- **Robuste Merkmale:**
  - Entstehen **nicht zufällig** in 3D-Szenen
  - **Zuverlässig lokalisierbar** bei:
    - unterschiedlichen Blickwinkeln
    - verschiedenen Beleuchtungsbedingungen

## Anforderungen an einen guten Corner Detector

- **Zuverlässige Erkennung** trotz Bildrauschen
- **Hohe Lokalisierungsgenauigkeit**
- **Effiziente Berechnung**

## Grundlagen der Eckpunkt detektion

- **Kante:** Bereich mit starkem Helligkeitsgradient in **einer Richtung**, orthogonal dazu gering
- **Ecke:** Punkt mit **starkem Helligkeitsunterschied in mehreren Richtungen gleichzeitig**

## Allgemeine Eigenschaften eines Interest Points

1. **Mathematisch eindeutig definierbar**
  2. **Eindeutige Position** im Bildraum
  3. **Hoher lokaler Informationsgehalt**
  4. **Stabilität** gegenüber:
    - Lokalen Störungen
    - Globalen Störungen (z. B. perspektivische Verzerrung, Beleuchtungsvariation)
  5. **Skalierungsinviananz**
- 

## Eckendetektion

### Detektionsprinzip

- Eckendetektoren reagieren nicht nur auf **Ecken**, sondern auch auf Bildregionen mit **hoher Variabilität in alle Richtungen**.
- Ein **Eckpunkt liegt vor**, wenn der **Gradient in mehreren Richtungen** stark ausgeprägt ist.

### Abgrenzung zu Kanten

- **Kanten:** Gradient stark **in einer Richtung** → **kein Eckpunkt**
- **Eckpunkt:** Starke Gradienten in **mehreren Richtungen gleichzeitig**

### Definition eines Eckpunkts

- **Schnittpunkt zweier Kanten**
- **Punkt mit zwei dominanten Kantenrichtungen** in seiner lokalen Umgebung
- Kann auch sein:
  - **Endpunkt einer Linie**
  - **Punkt auf einer Kurve mit maximaler Krümmung**

### Anforderungen an die Detektion

- **Isotrope Erkennung:** Unabhängig von Orientierung
- **Robustheit** gegenüber:
  - **Unterschiedlichen Lichtverhältnissen**
  - **Geometrischen Transformationen** wie:

- Translation
- Rotation

## Qualitätskriterium für Eckendetektoren

- Wiedererkennung derselben Ecke unter verschiedenen Bedingungen (Beleuchtung, Transformation)

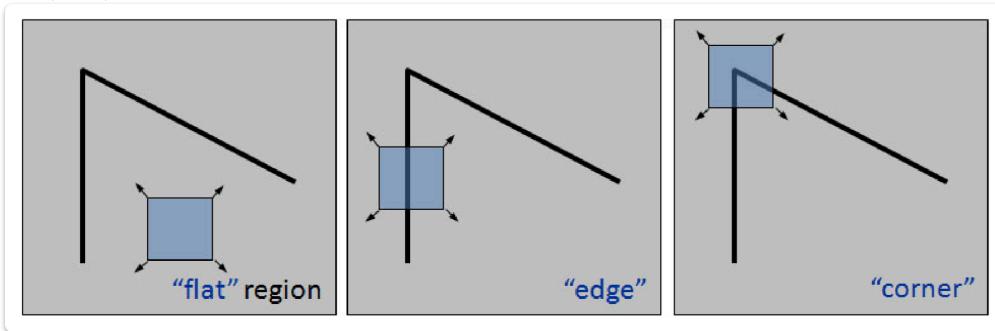
## Moravec-Eckendetektor

### Ursprung

- Einer der ersten Eckendetektoren
- Entwickelt von Hans P. Moravec
- Einführung des Begriffs "Points of Interest"

### Grundidee

- Eine Ecke wird als Punkt mit geringer Ähnlichkeit zum verschobenen Fensterinhalt definiert.
- Verwendet ein lokales Fenster  $w(x, y)$  zur Analyse der Intensitätsveränderungen.
- Fenster wird in vier Richtungen leicht verschoben:
  - Für jede Verschiebung wird die Intensitätsveränderung berechnet:
    - $I(x + u, y + v)$ : Intensität an verschobener Stelle
    - $I(x, y)$ : ursprüngliche Intensität



$$E(u, v) = \sum_{x, y} w(x, y) [I(x+u, y+v) - I(x, y)]^2$$

Window function

Shifted intensity

Intensity

Window function  $w(x, y) =$



1 in window, 0 outside

## Interest Value

- Für jede **Pixelposition** wird ein **Interest Value** berechnet:
  - Entspricht der **minimalen Intensitätsänderung** bei allen Verschiebungen

## Interpretation der Interest Values

- Geringe Veränderungen in alle Richtungen → **flache Region**
- Hohe Veränderung nur in einer Richtung → **Kante**
- Hohe Veränderung in mehreren Richtungen → **Ecke**

## Nachteile des Moravec-Operators

- **Anisotropische Antwort:**
  - Kanten, die **nicht exakt** in Verschieberichtungen verlaufen, können fälschlich als Ecken erkannt werden
- **Empfindlich gegenüber Bildrauschen:**
  - Besonders entlang von Kanten
  - Betrachtet nur **Minimale Intensitätsänderungen**, nicht deren Verteilung

## Harris Eckendetektor

### Verbesserung gegenüber Moravec

- Statt **absoluter Pixeldifferenzen** (wie bei Moravec) wird die **Variation der lokalen Bildstruktur** analysiert.
- Verwendet die **Bildgradienten** zur Erkennung von Ecken:
  - An einem **Eckpunkt** sind die Gradienten sowohl in der **Hauptrichtung** als auch **orthogonal dazu** signifikant

## Vorteile

- Zuverlässigere Detektion und Wiedererkennung von Ecken
- **Isoptre Antwort:**
  - **Rotationsinvariant**
  - Kein bevorzugter Richtungsverlauf wie bei Moravec

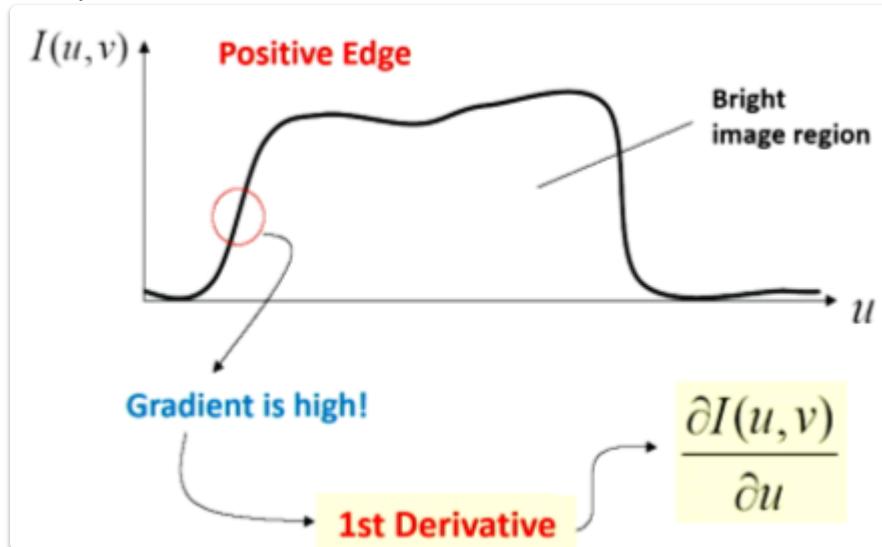
## Nachteile

- **Höherer Rechenaufwand** durch komplexere Berechnungen
- **Nicht skalierungsinvariant** (wie auch der Moravec-Detektor)

# Skaleninvariante Merkmalsumwandlung (SIFT)

## Allgemeines

- **SIFT (Scale-Invariant Feature Transform)**: Algorithmus zur **Dektection und Beschreibung** lokaler Merkmale in Bildern.
  - Entwickelt von **David Lowe** im Jahr **1999** und in den **USA patentiert**.
  - **Eigenschaften**:
    - **Skalierungs invariant**: Unabhängig von der Bildgröße
    - **Rotationsinvariant**: Unabhängig von der Orientierung des Bildes
    - **Robust gegenüber**:
      - Affinen Transformationen
      - Beleuchtungsveränderungen
- Was passiert an einer Ecke?

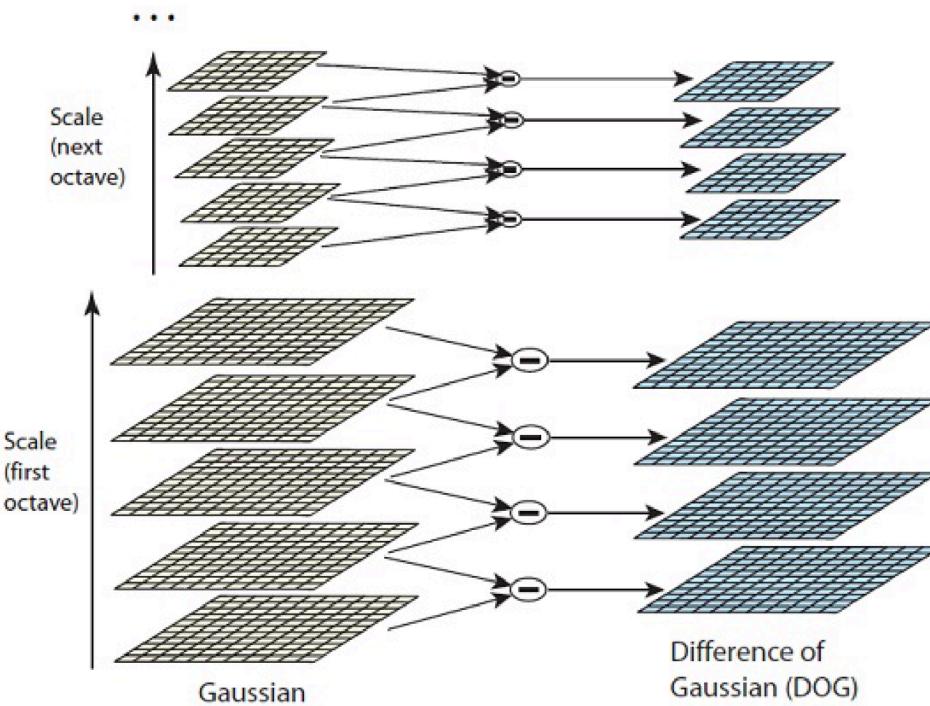


- Die Umwandlung erfolgt in **4 Schritten**:

## 1. Finden von Interest Points – Skalierung

### Difference of Gaussians (DoG)

- SIFT verwendet eine **Difference-of-Gaussians (DoG)**-approximierte **Laplacepyramide**.
  - Der Hauptunterschied zur **ursprünglichen Laplacepyramide**:
    - Es erfolgen **keine Größenänderungen** zwischen den Ebenen, die Auflösung bleibt konstant.



- Functions for determining scale

$$f = \text{Kernel} * \text{Image}$$

Kernels:

$$L = \sigma^2 (G_{xx}(x, y, \sigma) + G_{yy}(x, y, \sigma))$$

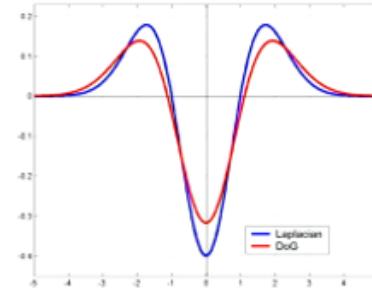
(Laplacian)

$$DoG = G(x, y, k\sigma) - G(x, y, \sigma)$$

(Difference of Gaussians)

where Gaussian:

$$G(x, y, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2+y^2}{2\sigma^2}}$$



Note: both kernels are invariant to scale and rotation

## DoG Filtering



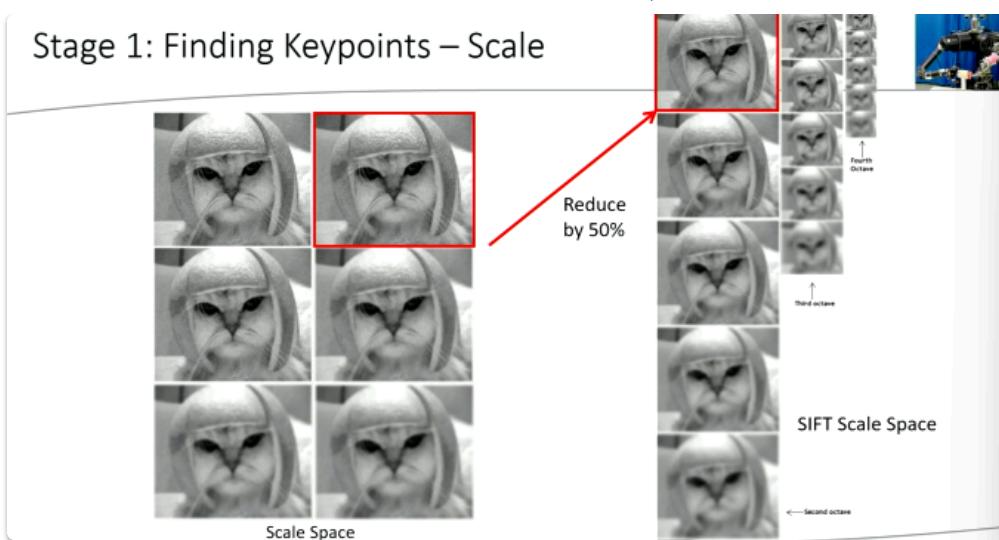
- Convolution with a variable-scale Gaussian

$$L(x, y, \sigma) = G(x, y, \sigma) * I(x, y),$$

$$G(x, y, \sigma) = 1/(2\pi\sigma^2) \exp^{-(x^2+y^2)/\sigma^2}$$

- Difference-of-Gaussian (DoG) filter  $G(x, y, k\sigma) - G(x, y, \sigma)$

- Convolution with the DoG filter  $D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma)$



## Oktaven und Anwendung der Gaußfilter

- **Oktave:** Eine Reihe von **5 aufeinanderfolgenden Gaußfiltern**, die insgesamt **4 bandpassgefilterte Ergebnisse** erzeugen.
- Nach der ersten Oktave wird die **nächste Ebene der Gaußpyramide** (2. Oktave) auf die gleiche Weise behandelt.
  - Jede Oktave reduziert die **Auflösung** des Bildes:
    - Erste Oktave: **Originalauflösung**
    - Zweite Oktave: **halbe Auflösung** in beiden Richtungen, und so weiter.

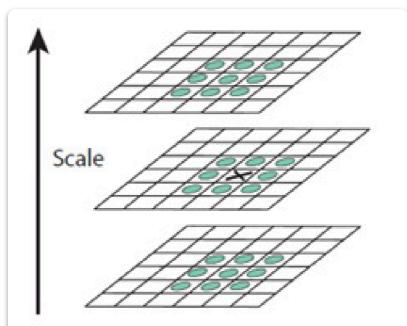
## DoG und Lokalisierung von Merkmalen

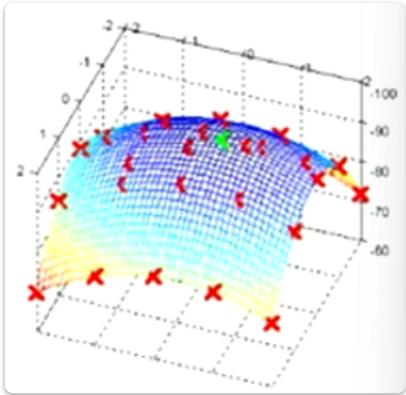
- **DoG Bilder** (oder auch **Laplacebilder**):
  - Trennen die **Frequenzen** im Bild
  - Dies hilft bei der **Lokalisation von Kanten** und **Ecken**

## Rolle der Oktaven

- **Extrema** werden durch das **Vergleichen von Bildpunkten** zwischen verschiedenen Oktaven lokalisiert.
- Die **verschiedenen Oktaven** sind entscheidend für die Erkennung von **Interest Points** auf unterschiedlichen Skalen.

## 2. Finden von Interest Points - Position





## Dreiteiliger Prozess zur Positionierung von Interest Points

### a) Lokalisierung der Extrema (Maxima/Minima) in den DoG-Bildern

- **Erster Schritt:** Grobe Lokalisierung der **Maxima und Minima**.
- **Vorgehensweise:**
  - Iterative Überprüfung der **Nachbarn** im DoG-Skalenraum.
  - Es werden **26 Abfragen** für jedes Pixel durchgeführt:
    - 9 Punkte in der gleichen Ebene
    - 9 Punkte in der Ebene darüber
    - 8 Punkte in der Ebene darunter
- **Kriterien:** Ein Interest Point ist **größer** oder **kleiner** als alle 26 benachbarten Punkte.

### b) Bestimmung der Position der Extrema mit Subpixel-Genauigkeit

- **Ziel:** Die genauen Positionen der **Maxima und Minima** zu bestimmen, da sie nicht unbedingt auf einem Pixel liegen, sondern auch zwischen den Pixeln.
- **Vorgehensweise:**
  - Nutzung der **Taylorreihenentwicklung**, um Subpixelwerte um den approximierten Interest Point zu berechnen.

### c) Eliminierung ungeeigneter Interest Points

- **Gründe für Eliminierung:**
  - Punkte liegen entlang von **Kanten**.
  - Punkte besitzen **nicht genügend Kontrast**.
- **Schritte zur Eliminierung:**
  1. **Kanten eliminieren:**
    - **Ähnlich wie der Harris-Detektor:**
      - Berechnung der **zwei Gradienten**, die senkrecht zueinander stehen.
      - **Möglichkeiten:**
        - **Flache Region:** Beide Gradienten sind klein.

- **Kante:** Ein Gradient ist groß (senkrecht zur Kante), der andere klein (entlang der Kante).
- **Ecke:** Beide Gradienten sind groß (wird als guter Interest Point betrachtet).

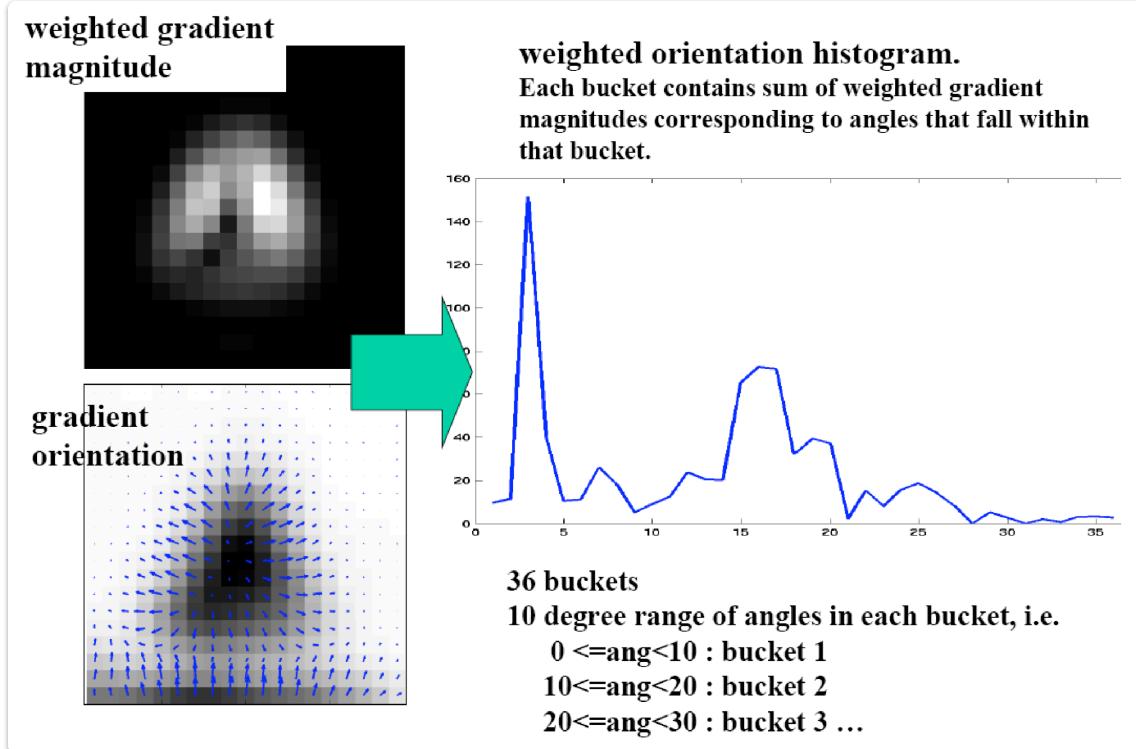
## 2. Geringer Kontrast:

- Kontrolle der **Intensitätswerte** im DoG-Bild.
- Wenn der Wert unter einem bestimmten **Schwellenwert** liegt, wird der Interest Point verworfen.

## 3. Finden von Interest Points – Orientierung

### Ziel

- **Rotationsinvarianz:** Der SIFT-Merkalsvektor für denselben Interest Point soll auch in einem rotierten Bild denselben Wert haben.



### Vorgehensweise

#### 1. Erhebung der Gradienten:

- Um den **rotationsinvarianten Merkmalsvektor** zu erstellen, werden die **Längen (Gradientenbeträge)** und **Richtungen der Gradienten** rund um den Interest Point gesammelt.

#### 2. Bestimmung der dominanten Gradientenrichtung:

- Die **dominante Gradientenrichtung** einer Region wird durch Bestimmung der Richtung des stärksten Gradienten in der Umgebung des Interest Points ermittelt.

#### 3. Histogramm der Gradientenrichtungen:

- Ein Histogramm wird erstellt, das die **360 Grad** der Gradientenrichtungen in **36 Bins** aufteilt (jeweils **10 Grad** pro Bin).
  - Beispiel: Eine Gradientenrichtung von **18,7 Grad** fällt in den Bin von **10-19 Grad**.
  - Der Wert des jeweiligen Bins entspricht der **Länge des Gradienten** an diesem Punkt.

#### 4. Dominante Richtung:

- Der **Bin** mit dem höchsten Wert im Histogramm wird als die **dominante Gradientenrichtung** des Interest Points festgelegt.

## Ergebnis

- Der Interest Point erhält eine **dominante Orientierung**, wodurch der SIFT-Merkalsvektor **rotationsinvariant** wird.

## 4. Erstellen einer Beschreibung der Merkmale

- Erstellung einer **eindeutigen Signatur** (Merkmalsvektor) für jeden Interest Point, die **robust gegenüber Störungen** und **rotations- sowie beleuchtungsinvariant** ist.

### Schritte zur Signaturerstellung

#### 1. 16x16 Fenster um den Interest Point:

- Ein **16x16 Fenster** wird um den Interest Point in seiner jeweiligen **Skalierung** definiert.
- Dieses Fenster wird in **16 4x4 Subfenster** unterteilt (siehe Abbildung 37).

#### 2. Berechnung der Gradienten in den Subfenstern:

- Innerhalb jedes **4x4 Subfensters** werden die **Richtungen** und **Längen der Gradienten** berechnet.
- Die Gradientenrichtungen werden in einem **Histogramm mit 8 Bins** zusammengefasst:
  - 0–44 Grad → 1. Bin
  - 45–89 Grad → 2. Bin
  - usw.

#### 3. Gewichtung der Gradienten:

- Der Wert, der einem Bin hinzugefügt wird, hängt von:
  - Der **Länge des Gradienten** (größere Gradienten haben mehr Einfluss).
  - Der **Entfernung zum Interest Point**:
    - Entferntere Gradienten werden mit einer **Gaußschen Gewichtungsfunktion** weniger stark gewichtet (siehe blauer Kreis in der Abbildung).

#### 4. Berechnung des Merkmalsvektors:

- Wiederhole den Prozess für alle **16 4x4 Subfenster**.
- Der resultierende Vektor hat  **$4 \times 4 \times 8 = 128$  Werte**.
- Diese 128 Werte bilden den **Merkmalsvektor** für den Interest Point.

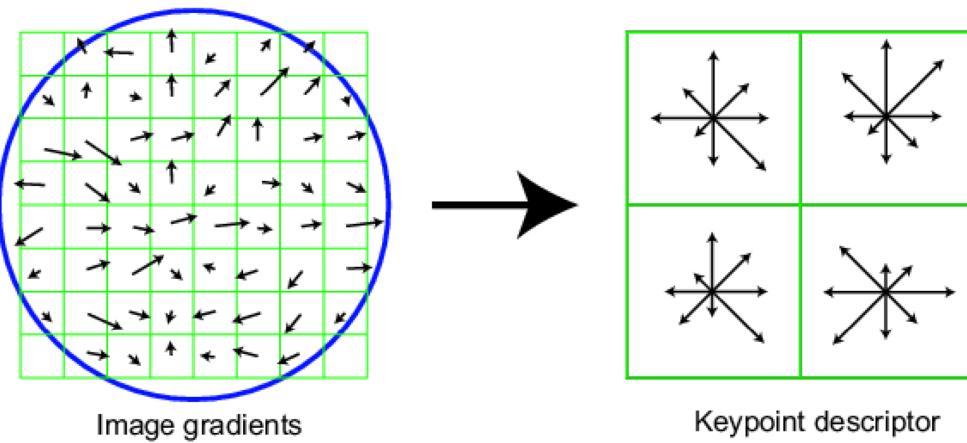
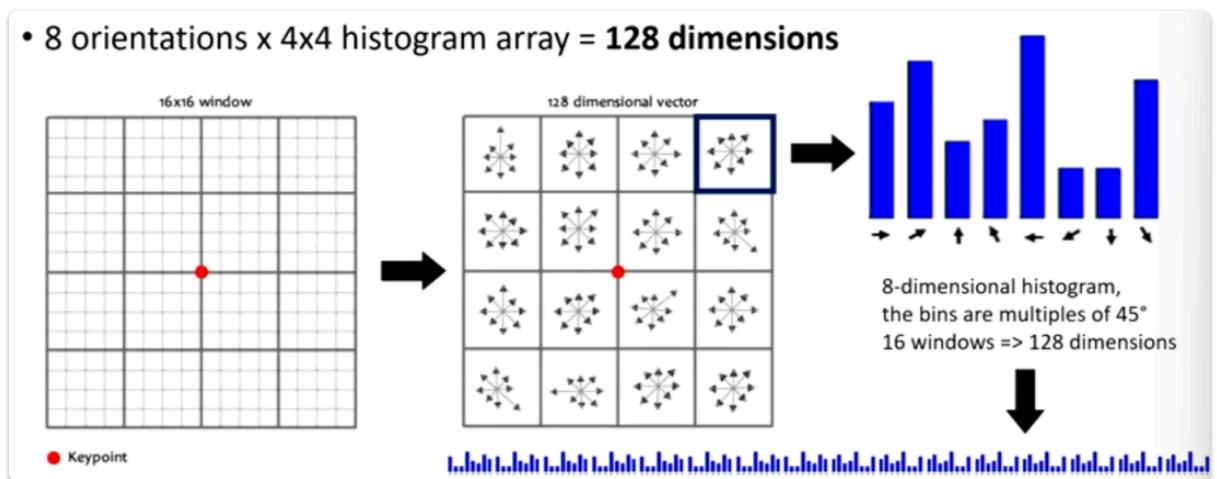


Abbildung 37: Berechnung der SIFT-Deskriptoren



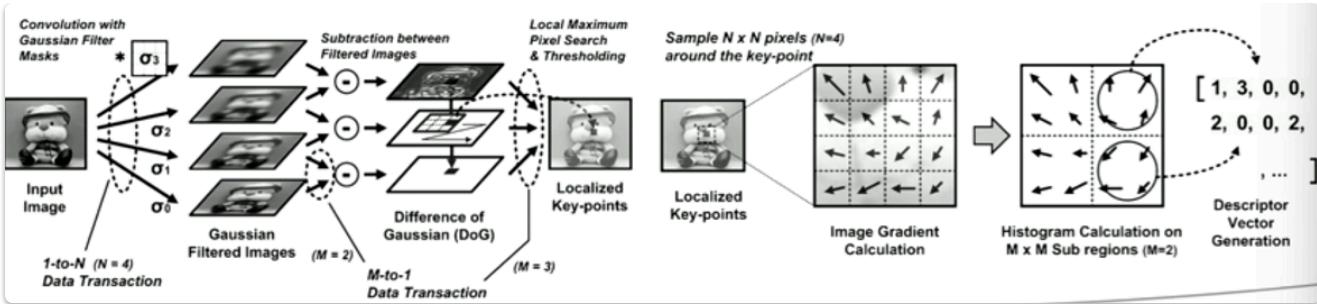
## Einschränkungen und Anpassungen

## 1. Rotationsabhängigkeit:

- Da der Merkmalsvektor auf **Gradientenrichtungen** basiert, verändern sich diese bei einer **Bildrotation**.
  - Um **Rotationsinvarianz** zu erreichen, wird die dem Interest Point zugewiesene **dominante Orientierung** von jeder Gradientenrichtung subtrahiert. Somit wird jede Gradientenrichtung relativ zur Orientierung des Interest Points angegeben.

## 2. Beleuchtungsabhängigkeit:

- Lichteffekte können die **Länge einzelner Gradienten** beeinflussen.
  - Um die Sensitivität gegenüber Beleuchtung zu verringern:
    - Alle Werte im Merkmalsvektor, die größer als **0.2** sind, werden auf **0.2** gesetzt.
  - Der Merkmalsvektor wird anschließend normalisiert, wodurch er weniger anfällig für Beleuchtungsvariationen wird.

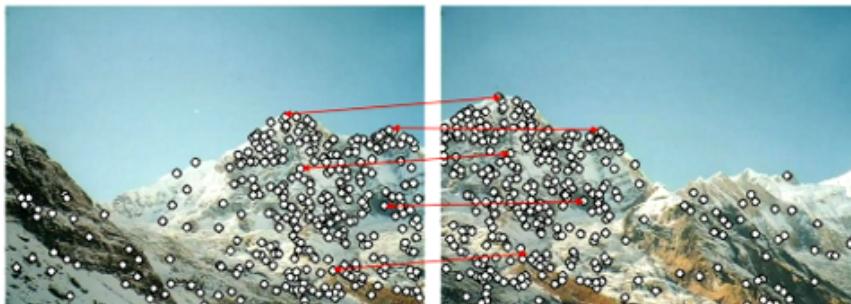


## Möglicher Anwendungsfall: Panoramaerstellung

- We need to match (align) images
- Global methods are sensitive to occlusion, lighting, and parallax effects. So, look for local features that match well.
- How would you do it by eye?



- Detect feature points in both images
- Find corresponding pairs



- Use these pairs to align images



# Testähnliches Beispiel

## Beispiel: Moravec-Eckendetektor



- Gegeben ist ein 5x5 großer Bildausschnitt, auf den der Moravec-Eckendetektor angewendet werden soll. Berechnen Sie die Veränderungen der Intensitäten  $E$  für die mit Stern \* markierte Stelle (3,3) und die 4 Verschiebungen (1,0), (1,1), (0,1) und (-1,1). Verwenden Sie dazu eine Fenstergröße von 3x3 und die Summe der quadrierten Differenzen (SSD, Sum of Squared Differences). Bestimmen Sie des weiteren aus den Veränderungen der Intensitäten den „Interest Value“.

y	1	70	60	70	60	60
1	70	80	80	90	80	80
2	80	80	90	80	80	80
3	80	90	100*	100	100	100
4	80	90	100	100	100	100
5	70	80	100	100	100	110
x	1	2	3	4	5	

$$E(u, v) = \sum_{x,y} w(x, y) [I(x+u, y+v) - I(x, y)]^2$$

E(1,0): SSD der Pixelwerte von  $\boxed{80}$  und  $\boxed{90}$ :

$E(1,0) = \underline{\hspace{2cm}}$

$E(1,1) = \underline{\hspace{2cm}}$

$E(0,1) = \underline{\hspace{2cm}}$

$E(-1,1) = \underline{\hspace{2cm}}$

Interest value:  $\underline{\hspace{2cm}}$

## Beispiel: Moravec-Eckendetektor



- Gegeben ist ein 5x5 großer Bildausschnitt, auf den der Moravec-Eckendetektor angewendet werden soll. Berechnen Sie die Veränderungen der Intensitäten  $E$  für die mit Stern \* markierte Stelle (3,3) und die 4 Verschiebungen (1,0), (1,1), (0,1) und (-1,1). Verwenden Sie dazu eine Fenstergröße von 3x3 und die Summe der quadrierten Differenzen (SSD, Sum of Squared Differences). Bestimmen Sie des weiteren aus den Veränderungen der Intensitäten den „Interest Value“.

y	1	70	60	70	60	60
1	70	80	80	90	80	80
2	80	80	90	80	80	80
3	80	90	100*	100	100	100
4	80	90	100	100	100	100
5	70	80	100	100	100	110
x	1	2	3	4	5	

$$E(u, v) = \sum_{x,y} w(x, y) [I(x+u, y+v) - I(x, y)]^2$$

E(1,0): SSD der Pixelwerte von  $\boxed{80}$  und  $\boxed{90}$ :

$$(90-80)^2 + (80-90)^2 + (80-80)^2 +$$

$$(100-90)^2 + (100-100)^2 + (100-100)^2 +$$

$$(100-90)^2 + (100-100)^2 + (100-100)^2 = 400$$

## Beispiel: Moravec-Eckendetektor



- Gegeben ist ein 5x5 großer Bildausschnitt, auf den der Moravec-Eckendetektor angewendet werden soll. Berechnen Sie die Veränderungen der Intensitäten  $E$  für die mit Stern \* markierte Stelle (3,3) und die 4 Verschiebungen (1,0), (1,1), (0,1) und (-1,1). Verwenden Sie dazu eine Fenstergröße von 3x3 und die Summe der quadrierten Differenzen (SSD, Sum of Squared Differences). Bestimmen Sie des weiteren aus den Veränderungen der Intensitäten den „Interest Value“.

$y$	1	70	60	70	60	60	$E(1,0)=$ <u>400</u>
2	80	80	90	80	80	80	$E(1,1)=$ <u>  </u>
3	80	90	100*	100	100	100	$E(0,1)=$ <u>  </u>
4	80	90	100	100	100	100	$E(-1,1)=$ <u>  </u>
5	70	80	100	100	100	110	Interest value: <u>  </u>
$x$	1	2	3	4	5		

$$E(u, v) = \sum_{x, y} w(x, y) [I(x+u, y+v) - I(x, y)]^2$$

$E(1,1)$ : SSD der Pixelwerte von    und   :

## Beispiel: Moravec-Eckendetektor



- Gegeben ist ein 5x5 großer Bildausschnitt, auf den der Moravec-Eckendetektor angewendet werden soll. Berechnen Sie die Veränderungen der Intensitäten  $E$  für die mit Stern \* markierte Stelle (3,3) und die 4 Verschiebungen (1,0), (1,1), (0,1) und (-1,1). Verwenden Sie dazu eine Fenstergröße von 3x3 und die Summe der quadrierten Differenzen (SSD, Sum of Squared Differences). Bestimmen Sie des weiteren aus den Veränderungen der Intensitäten den „Interest Value“.

$y$	1	70	60	70	60	60	$E(1,0)=$ <u>400</u>
2	80	80	90	80	80	80	$E(1,1)=$ <u>1.200</u>
3	80	90	100*	100	100	100	$E(0,1)=$ <u>700</u>
4	80	90	100	100	100	100	$E(-1,1)=$ <u>1.400</u>
5	70	80	100	100	100	110	Interest value: <u>400</u>
$x$	1	2	3	4	5		

$$E(u, v) = \sum_{x, y} w(x, y) [I(x+u, y+v) - I(x, y)]^2$$

**Interest Value:** Minimum der 4 Werte