

Cheatsheet

1. Wahrscheinlichkeitstheorie

Mengenlehre & Grundlagen

- **Inklusion-Exklusion (2 Mengen):** $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
- **Bedingte Wahrscheinlichkeit:** $P(A|B) = \frac{P(A \cap B)}{P(B)}$
- **Unabhängigkeit:** A, B unabhängig $\Leftrightarrow P(A \cap B) = P(A) \cdot P(B)$
 - **Achtung:** Aus $P(A|B) = P(A)$ folgt Unabhängigkeit.
- Satz von Bayes:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)} = \frac{P(B|A) \cdot P(A)}{\sum_i P(B|H_i)P(H_i)}$$

Kombinatorik

- **Permutation** (Anordnung von n Elementen): $n!$
- **Binomialkoeffizient** (Auswahl k aus n ohne Zurücklegen, ohne Reihenfolge): $\binom{n}{k} = \frac{n!}{k!(n-k)!}$
- **Variation** (Auswahl k aus n mit Beachtung der Reihenfolge): $\frac{n!}{(n-k)!}$

Zufallsvariablen (Rechenregeln!)

Für Konstanten a, b, c :

- Erwartungswert: Linearität!

$$E[aX + bY + c] = aE[X] + bE[Y] + c$$

- Varianz:

$$Var(X) = E[X^2] - (E[X])^2$$

$$Var(aX + b) = a^2 Var(X)$$

$$Var(X + Y) = Var(X) + Var(Y) + 2Cov(X, Y)$$

(Wenn X, Y unabhängig, ist $Cov(X, Y) = 0$)

- Kovarianz: Maß für linearen Zusammenhang

$$Cov(X, Y) = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$$

$$Cov(aX + c, bY + d) = a \cdot b \cdot Cov(X, Y)$$

Wichtig für Alttests: Konstanten, die addiert werden (+c, +d), fallen bei Cov weg!

Wichtige Verteilungen

Verteilung	Notation	Wahrscheinlichkeitsfunktion (PMF) / Dichte	$E[X]$	$Var(X)$
Bernoulli	$B(p)$	$P(X = 1) = p, P(X = 0) = 1 - p$	p	$p(1 - p)$

Verteilung	Notation	Wahrscheinlichkeitsfunktion (PMF) / Dichte	E[X]	Var(X)
Binomial	$B(n, p)$	$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$	np	$np(1 - p)$
Poisson	$Poi(\lambda)$	$P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}$	λ	λ
Gleichvert.	$U(a, b)$	$f(x) = \frac{1}{b-a}$ für $x \in [a, b]$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Normal	$N(\mu, \sigma^2)$	Dichte symmetrisch um μ	μ	σ^2

- Z-Transformation (Standardisierung):

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

$$P(X \leq x) = \Phi\left(\frac{x - \mu}{\sigma}\right)$$

- Zentraler Grenzwertsatz (CLT): Summen/Mittelwerte von unabhängigen ZV sind für großes n ($n > 30$) annähernd normalverteilt:

$$\bar{X} \approx N\left(\mu, \frac{\sigma^2}{n}\right)$$

2. Deskriptive Statistik

Kennzahlen

- **Arithmetisches Mittel:** $\bar{x} = \frac{1}{n} \sum x_i$
- Empirische Varianz (korrigiert):

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

- **Standardabweichung:** $s = \sqrt{s^2}$
- **Median:** Der mittlere Wert (bei ungeradem n) oder Mittelwert der beiden mittleren (bei geradem n) der *geordneten* Daten. (Robust gegen Ausreißer).
- **Quantile:** q_p (z.B. $Q_1 = q_{0.25}$, $Q_3 = q_{0.75}$).
- **IQR (Interquartilsabstand):** $IQR = Q_3 - Q_1$.
 - **Boxplot Whisker:** Gehen bis max. $1.5 \cdot IQR$. Alles darüber hinaus sind Ausreißer.

Korrelation (Pearson)

$$r_{xy} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}} = \frac{s_{xy}}{s_x s_y}$$

- $-1 \leq r \leq 1$.
- $r = 0$: Kein *linearer* Zusammenhang (kann aber nicht-linear abhängig sein!).

3. Schließende Statistik (Inference)

Konfidenzintervalle (KI)

Allgemeine Form: Punktschätzer $\pm$ Kritischer Wert $\cdot$ Standardfehler (SE)

1. Mittelwert μ (Bekannte Varianz σ^2):

$$\left[\bar{x} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \quad \bar{x} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

2. Mittelwert μ (Unbekannte Varianz, n klein, normalverteilt):

$$\left[\bar{x} - t_{n-1, 1-\alpha/2} \frac{s}{\sqrt{n}}, \quad \bar{x} + t_{n-1, 1-\alpha/2} \frac{s}{\sqrt{n}} \right]$$

3. Anteilswert p (großes n): $\hat{p} \pm z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$

Wichtige Z-Quantile: $z_{0.95} \approx 1.645$, $z_{0.975} \approx 1.96$ (für 95% KI).

Hypothesentests

Logik:

- H_0 : Nullhypothese (Status Quo, "kein Effekt").
- H_1 : Alternativhypothese (Das, was wir zeigen wollen).
- **p-Wert:** Wahrscheinlichkeit, unter H_0 die beobachteten Daten (oder extremere) zu erhalten.
 - $p \leq \alpha \Rightarrow H_0$ ablehnen ("signifikant").
 - $p > \alpha \Rightarrow H_0$ beibehalten.

Fehlerarten (Wichtig für MC-Fragen!):

- **Fehler 1. Art (α):** H_0 ist wahr, wird aber abgelehnt. ("Falscher Alarm")
- **Fehler 2. Art (β):** H_1 ist wahr, H_0 wird aber beibehalten. ("Effekt übersehen")
- **Power (Macht, $1 - \beta$):** Wahrscheinlichkeit, H_0 korrekt abzulehnen, wenn H_1 wahr ist.
 - Power steigt mit: größerem n , größerem α , größerem Effekt, kleinerer Varianz.

Test-Übersicht

Test	Voraussetzung	Teststatistik	Verteilung unter H_0
Z-Test (1 Stichprobe)	σ bekannt (oder n groß)	$Z = \frac{\bar{x} - \mu_0}{\sigma / \sqrt{n}}$	$N(0, 1)$
t-Test (1 Stichprobe)	σ unbekannt, n klein	$T = \frac{\bar{x} - \mu_0}{s / \sqrt{n}}$	t_{n-1}
t-Test (2 Stichpr. unabh.)	Varianzen gleich	$T = \frac{\bar{x}_1 - \bar{x}_2}{s_p \sqrt{1/n_1 + 1/n_2}}$	$t_{n_1 + n_2 - 2}$
Welch-Test (2 Stichpr.)	Varianzen ungleich	$T = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$	t_ν (komplizierte df)

Test	Voraussetzung	Teststatistik	Verteilung unter H_0
Gepaarter t-Test	Vorher/Nachher (abhängig)	$d_i = x_i - y_i$. Teste $\bar{d}$ wie 1-Sample	t_{n-1}
Anteilswert-Test	Großes n	$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}$	$N(0, 1)$

Hinweis gepoolte Varianz (s_p^2): $s_p^2 = \frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2}$

Chi-Quadrat Test (Unabhängigkeit)

Für Kontingenztafeln (Kreuztabellen).

- H_0 : Variablen sind unabhängig.
- Erwartete Häufigkeit pro Zelle: $E_{ij} = \frac{\text{Zeilensumme} \cdot \text{Spaltensumme}}{\text{Gesamtsumme}}$
- Teststatistik:

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

- Freiheitsgrade: $df = (\text{Zeilen} - 1)(\text{Spalten} - 1)$

4. Weitere Tests & Verteilungs-Checks (Ergänzung)

Voraussetzungen für Normalverteilungs-Approximation (Faustregeln)

Wann darf man den Z-Test / CLT verwenden?

- Allgemein (Mittelwerte): $n \geq 30$
- Anteilswerte (Proportionen):
 - $n \cdot p > 15$ und $n \cdot (1 - p) > 15$
 - (Manchmal auch > 10 oder > 5 in Literatur, aber Slides sagen explizit > 15)

Z-Test für zwei Anteilswerte (2 Stichproben)

Vergleich von zwei Proportionen $\hat{p}_1$ und $\hat{p}_2$.

- Hypothese: $H_0 : p_1 = p_2$
- Gepoolter Anteil: $\hat{p} = \frac{x_1 + x_2}{n_1 + n_2}$ (Gesamtanteil der Erfolge)
- Teststatistik:

$$Z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1 - \hat{p}) \cdot \left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \sim N(0, 1)$$

Chi-Quadrat Anpassungstest (Goodness of Fit)

Testet, ob Daten einer bestimmten Verteilung folgen (z.B. "Ist der Würfel fair?").

- Daten: k Kategorien mit beobachteten Häufigkeiten O_i .

- **Erwartete Häufigkeiten (E_i):** $E_i = n \cdot p_i$ (unter H_0).
- **Teststatistik:**

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

- **Freiheitsgrade:** $df = k - 1 - m$
 - k : Anzahl der Kategorien
 - m : Anzahl der aus den Daten geschätzten Parameter (wenn Verteilung voll bekannt ist, ist $m = 0 \Rightarrow df = k - 1$).

5. Lineare Regression (Simple Linear Regression)

Modell: $Y = \beta_0 + \beta_1 X + \epsilon$ mit $\epsilon \sim N(0, \sigma^2)$

Kleinste-Quadrate-Schätzung (Least Squares)

Wir suchen Gerade $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$, die den quadratischen Fehler minimiert.

Hilfsgrößen (S):

- $S_{xx} = \sum (x_i - \bar{x})^2$
- $S_{yy} = \sum (y_i - \bar{y})^2$
- $S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$

Schätzer:

1. **Steigung (Slope):**

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = r_{xy} \frac{s_y}{s_x}$$

2. **Achsenabschnitt (Intercept):**

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Bestimmtheitsmaß R^2

Gibt an, wie viel Varianz der Daten durch das Modell erklärt wird.

$$R^2 = \frac{S_{xy}^2}{S_{xx} S_{yy}} = r_{xy}^2$$

- $R^2 \in [0, 1]$. Je näher an 1, desto besser das Modell.

Inferenz & Intervalle (Regression)

- **Standardfehler der Residuen (s):**

$$s^2 = \frac{\sum (y_i - \hat{y}_i)^2}{n - 2} = MSE$$

- **t-Test für Steigung** ($H_0 : \beta_1 = 0$, also kein linearer Zshg.):

$$T = \frac{\hat{\beta}_1}{s / \sqrt{S_{xx}}} \sim t_{n-2}$$

- **Prognose-Intervall (Prediction Interval)**: Für einen **neuen** einzelnen Wert y an der Stelle x^* (breiter als Konfidenzintervall!):

$$\hat{y} \pm t_{n-2, 1-\alpha/2} \cdot s \cdot \sqrt{1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}}$$

I have data on the daily high temperature (in Celsius) in Vienna and the daily total revenue from ice cream sales at Eis Greissler locations in Vienna (in thousands of Euros). The relationship is linear, and the correlation between the two variables is $r = 0.4$.

For a day in which the high temperature was 1 standard deviation above the mean, what would be our best estimate for the standardized value of ice cream sales at Eis Greissler?

- ☐ a. -0.4
- ☐ b. 0.4
- ☐ c. We cannot say without knowing the estimated slope, b_1 .
- ☐ d. We cannot say without knowing the standard deviations of temperature and revenue.

Wenn man beide Variablen (hier Temperatur und Umsatz) standardisiert – also in Z-Werte umrechnet –, passiert etwas sehr Praktisches mit der Regressionsgeraden:

1. Der Achsenabschnitt fällt weg (die Gerade geht durch den Ursprung).
2. Die **Steigung** der Geraden entspricht genau dem **Korrelationskoeffizienten** r .

Die Formel für die Schätzung sieht dann so einfach aus:

$$\hat{z}_y = r \cdot z_x$$

- (15) Suppose the correlation of two random variables X, Y is negative. Given two points (x_1, y_1) and (x_2, y_2) from the scatterplot, which of the following is possible?

- I. $x_1 > x_2$ and $y_1 < y_2$.
- II. $x_1 > x_2$ and $y_1 > y_2$.
- III. $x_1 < x_2$ and $y_1 > y_2$.

- ☒ a. I, II and III
- b. Only I
- c. I and II
- d. Only II

Der Korrelationskoeffizient liegt immer im Intervall $[-1, 1]$.

Wert	Korrelationstyp	Bedeutung
$r \approx 1$	Stark positiv	Variablen steigen/sinken gemeinsam (gleiche Richtung).
$r \approx 0$	Keine (Nullkorrelation)	Kein linearer Zusammenhang erkennbar.
$r \approx -1$	Stark negativ	Eine Variable steigt, die andere sinkt (Gegenbewegung).

- **Positiv:** Punktwolke steigt von links unten nach rechts oben.
- **Negativ:** Punktwolke fällt von links oben nach rechts unten.
- **Null:** Punkte sind zufällig verteilt (wie eine Wolke/Kreis).

⚠ Wichtig für die Uni

Korrelation impliziert keine Kausalität! Nur weil zwei Dinge korrelieren (z. B. Eisverkauf und Sonnenbrände), muss das eine nicht die Ursache für das andere sein (beides wird durch die Sonne verursacht).

- (17) In a simple linear regression model $y_i = ax_i + b + \epsilon_i$ the parameters are estimated via least squares. For the mean and the empirical variance of the x and y values we obtain $\bar{x} = 5$, $s_x^2 = 4$, $\bar{y} = 7$ and $s_y^2 = 9$. It holds that
- the regression line goes through $(7, 7)$.
 - the slope of the regression line is larger than 1.5.
 - the slope of the regression line is smaller than or equals 1.5.
 - the regression line goes through $(5, 6)$.

Solution: The regression line is $y = ax + b$, where the slope a is given as

$$a = r \cdot \frac{s_y}{s_x} = r \cdot 1.5$$

with r being the estimated correlation between X and Y , which means that $|r| \leq 1$. Therefore, $a = r \cdot 1.5 \leq 1.5$.

Moreover, we know that the regression line passes through the center of mass, which is $(\bar{x}, \bar{y}) = (5, 7)$, invalidating the given options.

I have data on the daily high temperature (in Celsius) in Vienna and the daily total revenue from ice cream sales at Eis Greissler locations in Vienna (in thousands of Euros). The relationship is linear, and the correlation between the two variables is $r = 0.4$.

For a day in which the high temperature was 2 standard deviation above the mean, what would be our best estimate for the standardized value of ice cream sales at Eis Greissler?

- ☐ a. 0.4
- ☐ b. We cannot say without knowing the estimated slope, b_1 .
- ☐ c. We cannot say without knowing the standard deviations of temperature and revenue.
- ☐ d. 0.8

Lineare Regression mit z-Scores

In der einfachen linearen Regression beschreibt die Gleichung für die Rohdaten die Beziehung $\hat{y} = b_0 + b_1x$. Wenn wir jedoch zu **standardisierten Werten** (z-Scores) übergehen, vereinfacht sich diese Beziehung erheblich.

Die fundamentale Formel

Für standardisierte Variablen gilt immer:

$$z_{\hat{y}} = r \cdot z_x$$

Hierbei ist:

- z_x : Der standardisierte Wert der unabhängigen Variable (Temperatur).
- $z_{\hat{y}}$: Der geschätzte standardisierte Wert der abhängigen Variable (Umsatz).
- r : Der Korrelationskoeffizient.

Berechnung für dieses Beispiel

Aus der Aufgabenstellung sind folgende Werte bekannt:

- Korrelation $r = 0.4$
- Die Temperatur liegt 2 Standardabweichungen über dem Mittelwert, also ist $z_x = 2$.

Einsetzen in die Formel:

$$z_{\hat{y}} = 0.4 \cdot 2 = 0.8$$

Let $X_1, \dots, X_{100}$ be a random sample from an exponential distribution with the expectation $\frac{1}{2}$. Determine the approximate value of

$$P\left(\sum_{i=1}^{100} X_i > 53\right)$$

using the Central limit theorem.

Recall, a random variable with probability density function

$$f(x) = \begin{cases} 2e^{-2x}, & x \geq 0 \\ 0, & x \leq 0 \end{cases}$$

is exponential with parameter $\lambda = 2$ and its expectation equals $\frac{1}{2}$.

Use the values given in the table below.

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051

Table 1: Cumulative distribution function of the standard normal distribution

- ☐ a. 0.345
- ☐ b. 0.309
- ☐ c. 0.271
- ☐ d. 0.274

Nach dem Zentralen Grenzwertsatz ist die Summe $S_n = \sum X_i$ für große n näherungsweise normalverteilt:

$$S_n \approx \mathcal{N}(n\mu, n\sigma^2)$$

Für $X \sim \text{Exp}(\lambda)$ gilt:

- $E(X) = \frac{1}{\lambda}$
- $\text{Var}(X) = \frac{1}{\lambda^2}$

1. Kenngrößen berechnen

- $n = 100$
- $\mu = \frac{1}{2} = 0.5$
- $\sigma^2 = \frac{1}{4} = 0.25$
- $\mu_S = 100 \cdot 0.5 = 50$ (für die Summe)
- $\sigma_S = \sqrt{100 \cdot 0.25} = 5$

2. Standardisierung (Z-Score)

Um die Standardnormalverteilungstabelle zu nutzen, wird der Wert $x = 53$ transformiert:

$$z = \frac{x - \mu_S}{\sigma_S} = \frac{53 - 50}{5} = 0.6$$

3. Wahrscheinlichkeit bestimmen

$$\begin{aligned}
 P(S_{100} > 53) &\approx P(Z > 0.6) \\
 &= 1 - \Phi(0.6) \\
 &= 1 - 0.7257 \quad (\text{laut Tabelle}) \\
 &= 0.2743
 \end{aligned}$$

Ergebnis: $P \approx \boxed{0.274}$

Wenn man nur Summe zusammenrechnet dann Formel wie sonst auch, wenn man durchschnitt hat vgl. Probetest 2026 dann macht man

$$\frac{\sigma}{\sqrt{n}}$$

A scientist tests 1000 hypotheses over his lifetime. Since he understands power well, he makes sure that each experiment is evaluated with a test that has exactly 60% power against a specific alternative hypothesis. He follows the usual tradition of doing tests at the 5% significance level. Suppose that, among all of the test that he performs in his lifetime, the null is actually true in 10% of the cases, while the specific alternative holds otherwise. In total, how many null hypotheses will he expect to reject?

- ☐ a. 545
- ☐ b. 650
- ☐ c. 550
- ☐ d. 600

2 Arten, einmal die die rejected werden sollen + die in einem Type1 Error...

H_0 true in 10% Cases $\implies 1000 \cdot 0.1 = 100$ von den 100 lehnt er fälschlicherweise 5 ab (5% significance Level)

H_1 true 90% Cases $\implies 900$. In diesen 900 Fällen lehnt er richtigerweise 60% (Power) ab...
 $900 \cdot 0.6 = 540$

$$540 + 5 = 545$$

A 95% confidence interval from a poll performed to estimate the population proportion of eligible voters who would not vote in the next Presidential election is (42%, 48%). Which of the following statements is **true**?

- ☐ a. The sample size that was used in the poll was approximately 30.
- ☐ b. The sample size that was used in the poll was approximately 1,050.
- ☐ c. The probability that the population proportion lies in this interval is 0.95.
- ☐ d. If the poll were to be repeated in an identical fashion then there is a 95% chance that the new sample proportion will lie in the range 42% to 48%.

Warum b) korrekt ist (Rechnung):

Das Intervall ist (42%, 48%). Daraus ergeben sich:

- Punktschätzer $\hat{p} = \frac{42+48}{2} = 45\% = 0,45$
- Fehlermarge $E = 48\% - 45\% = 3\% = 0,03$

Die Formel für die Fehlermarge bei einem 95% CI ($z \approx 1,96$) ist:

$$E = z \cdot \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

Umstellen nach n :

$$n = \frac{z^2 \cdot \hat{p}(1 - \hat{p})}{E^2}$$

$$n = \frac{1,96^2 \cdot 0,45 \cdot 0,55}{0,03^2} \approx \frac{3,8416 \cdot 0,2475}{0,0009} \approx 1056,44$$

Der Wert liegt also bei ca. 1.050, was Antwort **b)** bestätigt.

Suppose box A contains 4 red and 5 blue coins and box B contains 6 red and 3 blue coins. A coin is chosen at random from box A and placed in box B. Finally, a coin is chosen at random from among those that are now in box B. What is the probability a red coin was transferred from box A to box B given that the coin chosen from box B is blue?

- ☐ a. 5/8
- ☐ b. 2/9
- ☐ c. 16/45
- ☐ d. 3/8

Transferieren:

$$P(T_R) = \frac{4}{9}$$

$$P(T_B) = \frac{5}{9}$$

Ziehen:

- **Fall 1 (T_R):** Rot wurde transferiert. Box B hat nun 7 Rot, 3 Blau.


$$P(Z_B | T_R) = \frac{3}{10}$$

- **Fall 2 (T_B):** Blau wurde transferiert. Box B hat nun 6 Rot, 4 Blau.

$$P(Z_B | T_B) = \frac{4}{10}$$

Satz von Bayes:

$$P(T_R | Z_B) = \frac{P(Z_B | T_R) \cdot P(T_R)}{P(Z_B)} = \frac{\frac{3}{10} \cdot \frac{4}{9}}{\frac{5}{9}} = \frac{32}{90} = \boxed{\frac{16}{45}}$$



Let X and Z be independent **random variables** and both $N(0, 1)$ -distributed. Let

$$Y := \frac{X+Z}{2}.$$

Then the correlation between X and Y is

- ☐ a. 0
- ☐ b. 1/4
- ☐ c. 1/2
- ☐ d. $\sqrt{2}/2$

Die richtige Antwort ist **d.** $\sqrt{2}/2$.

Der Rechenweg

Gesucht ist die Korrelation $\rho(X, Y)$. Die Formel lautet:

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \cdot \sigma_Y}$$

Wir wissen aus der Angabe:

- $X, Z \sim N(0, 1)$ (Standardnormalverteilt)
- Das bedeutet: $\text{Var}(X) = 1$ und $\text{Var}(Z) = 1$. Somit ist auch $\sigma_X = 1$.
- X und Z sind unabhängig, also ist $\text{Cov}(X, Z) = 0$.
- $Y = \frac{X+Z}{2} = 0.5X + 0.5Z$

Schritt 1: Kovarianz berechnen ($\text{Cov}(X, Y)$)

Wir nutzen die Linearität der Kovarianz:

$$\begin{aligned} \text{Cov}(X, Y) &= \text{Cov}\left(X, \frac{X+Z}{2}\right) \\ &= \frac{1}{2} \cdot \text{Cov}(X, X+Z) \\ &= \frac{1}{2} \cdot (\text{Cov}(X, X) + \text{Cov}(X, Z)) \end{aligned}$$

Da $\text{Cov}(X, X) = \text{Var}(X) = 1$ und $\text{Cov}(X, Z) = 0$ (Unabhängigkeit):

$$\text{Cov}(X, Y) = \frac{1}{2} \cdot (1 + 0) = 0.5$$

Schritt 2: Standardabweichung von Y berechnen (σ_Y)

Dazu brauchen wir zuerst die Varianz. Bei unabhängigen Variablen gilt $\text{Var}(aX + bZ) = a^2 \text{Var}(X) + b^2 \text{Var}(Z)$.

$$\begin{aligned}\text{Var}(Y) &= \text{Var}(0.5X + 0.5Z) \\ &= 0.5^2 \cdot \text{Var}(X) + 0.5^2 \cdot \text{Var}(Z) \\ &= 0.25 \cdot 1 + 0.25 \cdot 1 \\ &= 0.5\end{aligned}$$

Die Standardabweichung ist die Wurzel daraus:

$$\sigma_Y = \sqrt{0.5} = \frac{1}{\sqrt{2}}$$

Schritt 3: In die Korrelationsformel einsetzen

$$\rho = \frac{0.5}{1 \cdot \sqrt{0.5}} = \frac{0.5}{\sqrt{0.5}} = \sqrt{0.5}$$

Mathematisch umgeformt (Bruch erweitern mit $\sqrt{2}$):

$$\sqrt{\frac{1}{2}} = \frac{1}{\sqrt{2}} = \frac{\sqrt{2}}{2}$$
